MBA EM

DATA SCIENCE

Deep Learning e Inteligência Artificial I

Prof. Luis Augusto Libório Oliveira Fonseca

Bruno Leandro Saraiva Ribeiro 231.087.883-53

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Bruno Leandro Saraiva Ribeiro 931.087.883-53

MBA USP ESALQ

PROFESSOR

Prof. MSc. Luis Augusto Libório O. Fonseca



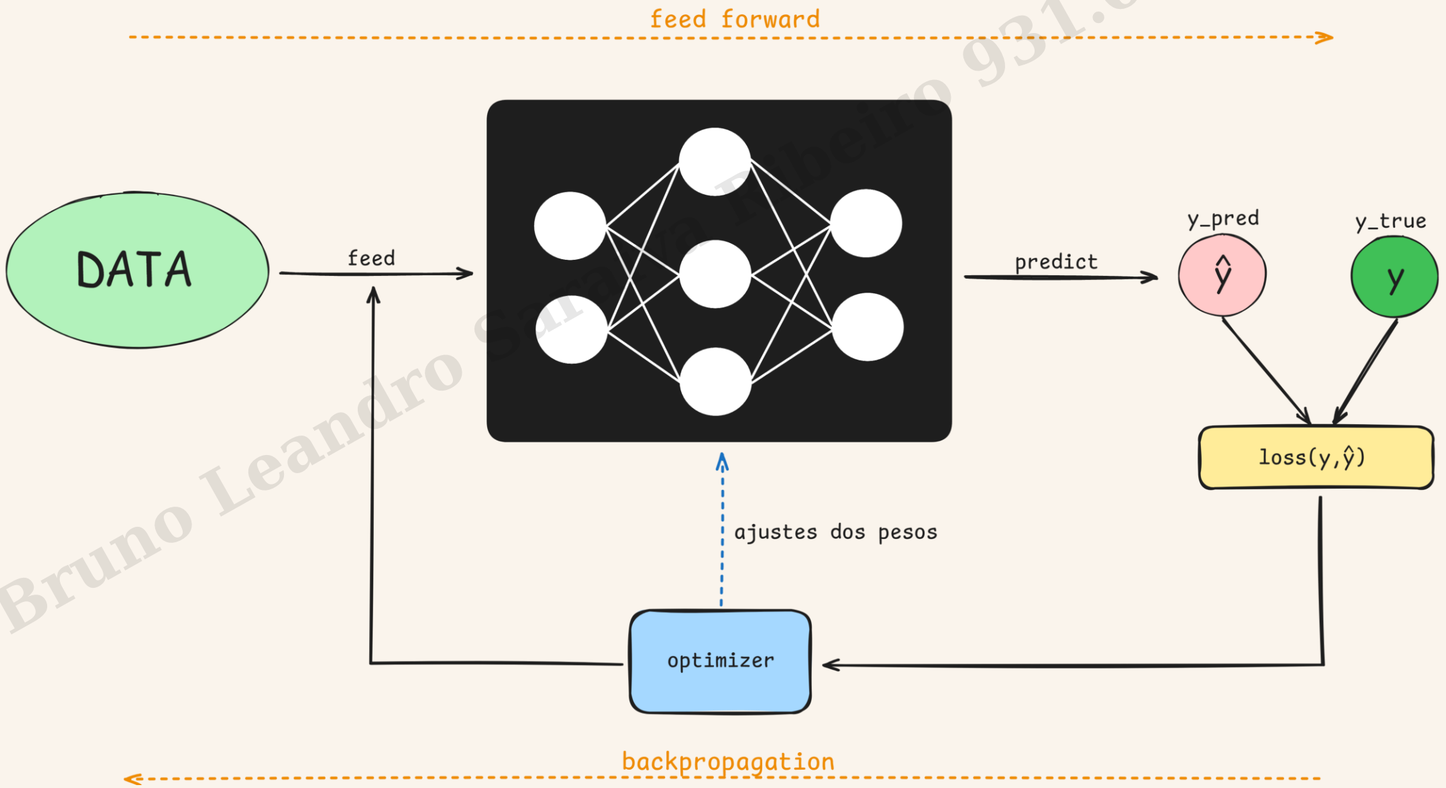
2018	Bacharel em Engenharia Mecatrônica — Unit
2021	Especialista em Mecatrônica — Unicamp
2022	MBA em Ciência de Dados — USP
2022	Mestre em Eng. Elétrica e Computação — Unicamp + Samsung
2023–24	Cientista em Machine Learning — Ford
2023–	Doutorando em Tecnologia — Unicamp
2024–	**Professor de pós-graduação**

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como redes neurais aprendem?

Aula 2 — Introdução ao Deep Learning



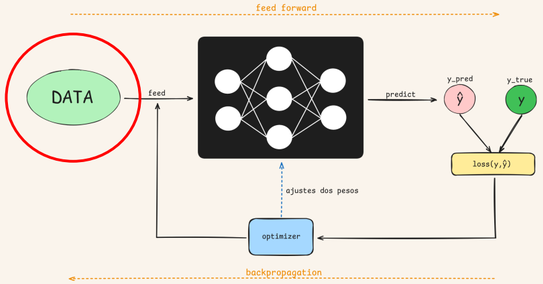
Bruno Leandro santos Pinheiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O PROBLEMA

Esse objeto é perigoso?

Objetos próximos da Terra (NEOs) monitorados por telescópios — cada linha é uma amostra, cada coluna uma feature.



ID	DIÂMETRO (KM)	VELOCIDADE (KM/S)	DIST. MÍNIMA (LD)	MAGNITUDE (H)	PERIGOSO?
NEO-114	0.42	18.3	3.1	21.4	SIM
NEO-207	0.05	9.1	14.7	25.8	NÃO
NEO-338	0.31	21.7	1.8	20.2	SIM
NEO-459	0.02	6.4	22.3	27.1	NÃO
NEO-582	0.18	14.9	6.5	23.0	NÃO

Bruno Leandro Saraiva Ribeiro 931.087.883-53

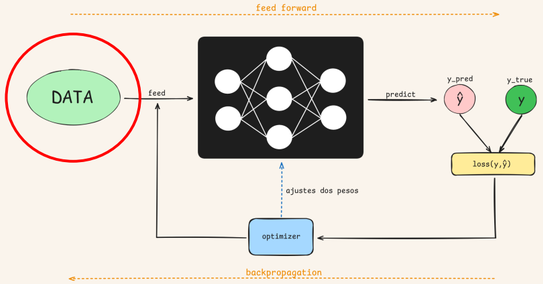
* dataset simulado para fins didáticos

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO 1 — ENTRADA

Uma amostra vira um vetor (tensor rank-1)

Isolamos uma linha do dataset — o objeto NEO-114 — e suas features numéricas formam o vetor de entrada x.



AMOSTRA: NEO-114

diâmetro: 0.42	velocidade: 18.3	dist. mín.: 3.1	magnitude: 21.4

↓

$$\begin{bmatrix} \text{diâmetro} & 0.42 \\ \text{velocidade} & 18.3 \\ \text{dist. mínima} & 3.1 \\ \text{magnitude} & 21.4 \end{bmatrix} = x$$

Y (RÓTULO REAL)

1

perigoso — não entra na rede

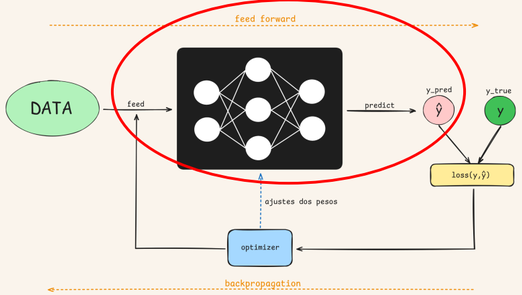
Bruno Leandro Saraiva Ribeiro 931.087.883-53

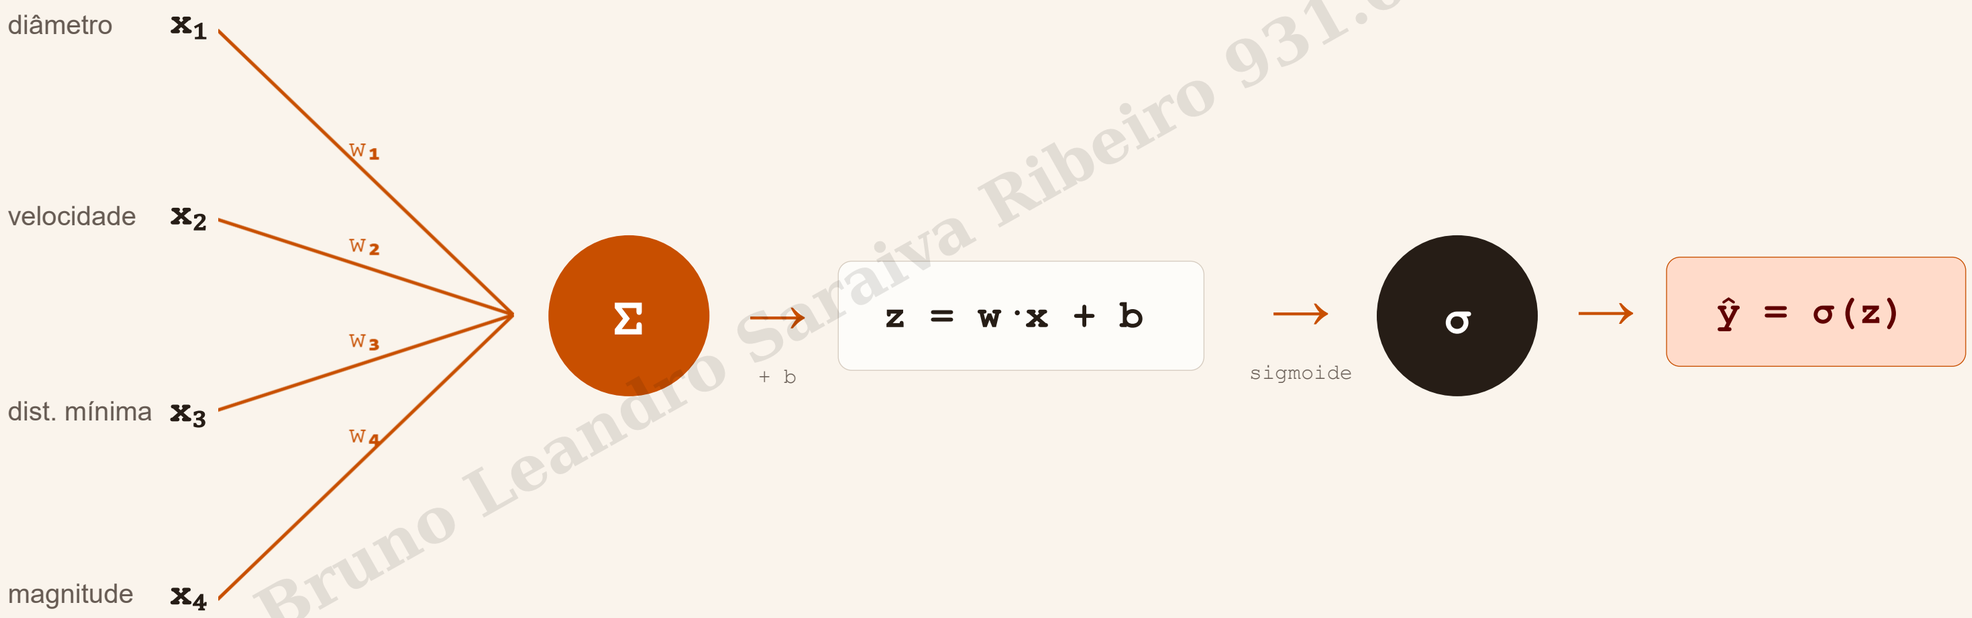
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO 2 — O NEURÔNIO

O vetor entra na rede

Um único neurônio combina cada feature com um peso, soma um bias, e passa o resultado por uma ativação não-linear.





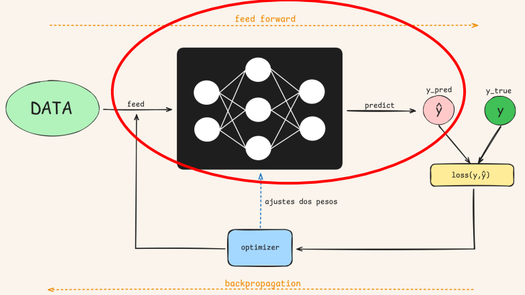
ŷ é a probabilidade estimada de o objeto ser perigoso (entre 0 e 1)

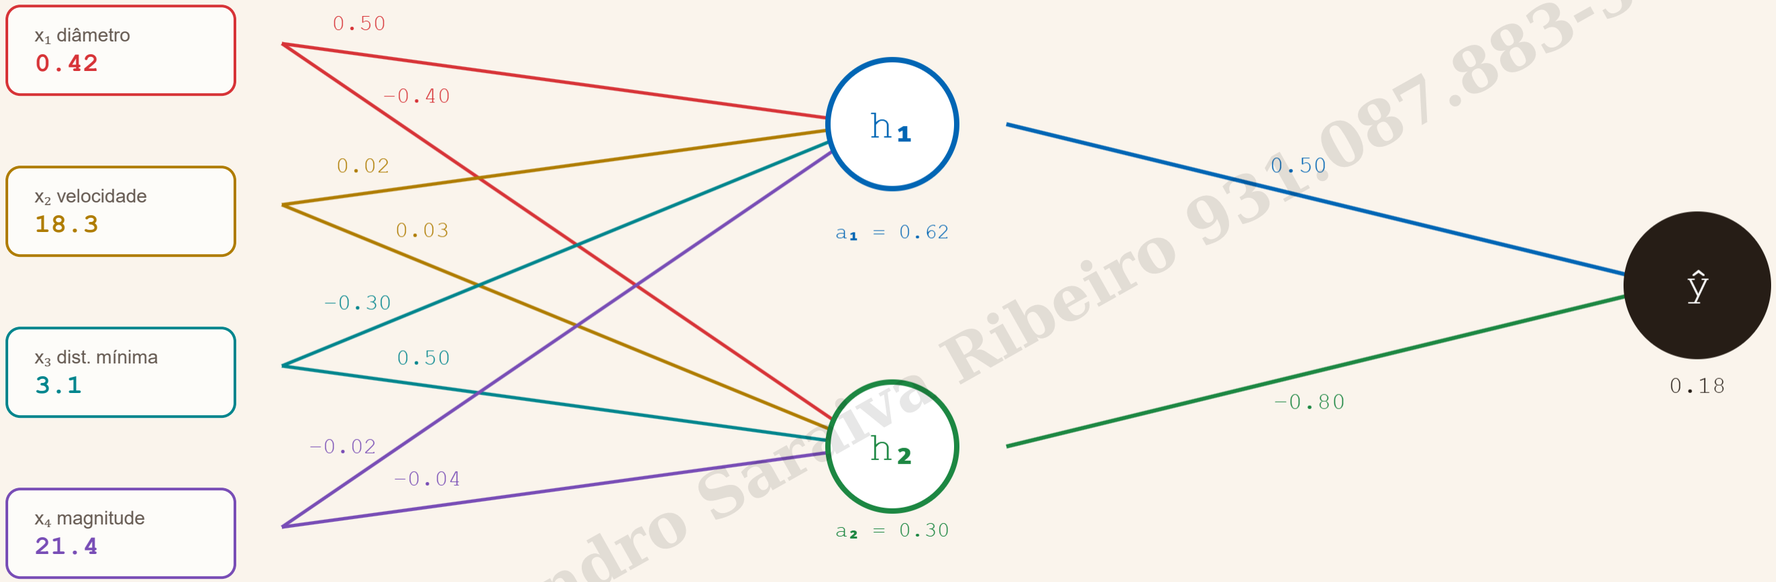
Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO 3 — PREDIÇÃO

Adicionando uma camada oculta (não linear)





Bruno Leandro Saraiva Ribeiro 934.087.883-53

$$z_{h1} = 0.50 \cdot x_1 + 0.02 \cdot x_2 + -0.30 \cdot x_3 + -0.02 \cdot x_4 + 1.25 = 0.47 \rightarrow a_1 = \sigma(z_{h1}) = 0.62$$

$$z_{h2} = -0.40 \cdot x_1 + 0.03 \cdot x_2 + 0.50 \cdot x_3 + -0.04 \cdot x_4 - 1.92 = -0.85 \rightarrow a_2 = \sigma(z_{h2}) = 0.30$$

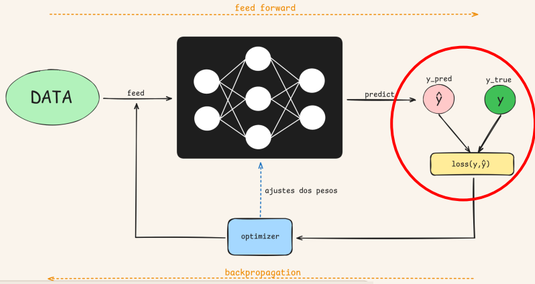
$$z_o = 0.50 \cdot a_1 + -0.80 \cdot a_2 - 1.59 = -1.52$$

$$\hat{y} = \sigma(z_o) = 0.18$$

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO 4 — REPETINDO PARA O DATASET

O mesmo cálculo, amostra por amostra ⇒ Loss



ID	Y	ŷ	|Y − Ŷ|	ERRO
NEO-114	1	0.18	0.82	
NEO-207	0	0.09	0.09	
NEO-338	1	0.20	0.80	
NEO-459	0	0.08	0.08	
NEO-582	0	0.12	0.12	
Média dos erros absolutos (MAE)			**0.38**	

$$MAE = (1/N) \cdot \Sigma \, |y_i - \hat{y}_i|$$

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

RESULTADO

0.38

Loss média do modelo (MAE)

Quanto menor a loss, melhor o modelo prevê a realidade. Com pesos ainda não treinados, este modelo erra bastante justamente nos casos perigosos.

Próximo passo: ajustar os pesos → Gradient Descent

Bruno Leandro Saraiva Ribeiro 331.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como diminuir o erro do modelo?

"Quem mede o erro do modelo?"

R: A função de perda (Loss)

"Quem determina a magnitude do erro?"

R: Os pesos do modelo (rede neural)

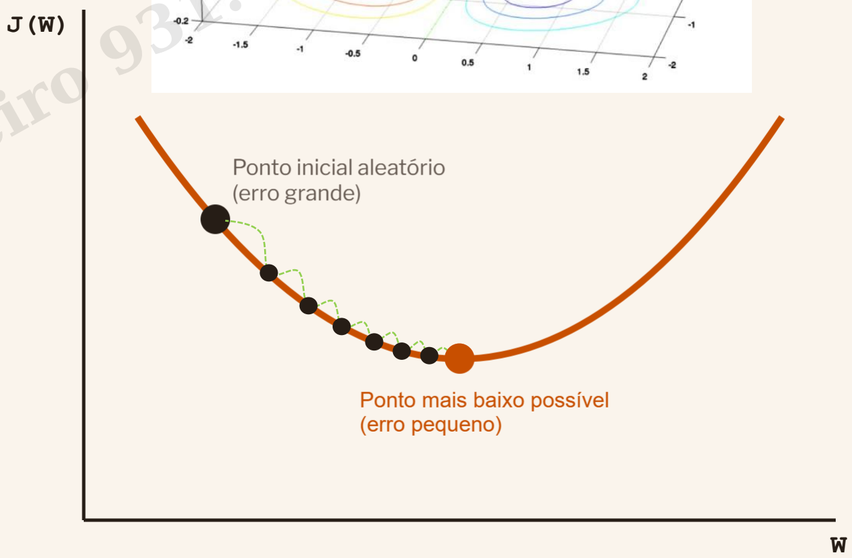
Bruno Leandro Saraiva Ribeiro 931.087.803-53

1. Devemos alterar os pesos do modelo de tal forma que os novos valores diminuam a loss.
2. Se soubermos a **taxa de variação da loss em relação aos pesos**, descobrimos o quanto alterá-los para que o erro varie em direção a zero.

`Algoritmo Gradient Descent`

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Descendo a montanha do erro



A partir de um ponto inicial aleatório, alcançar o ponto mais baixo da superfície J(W):

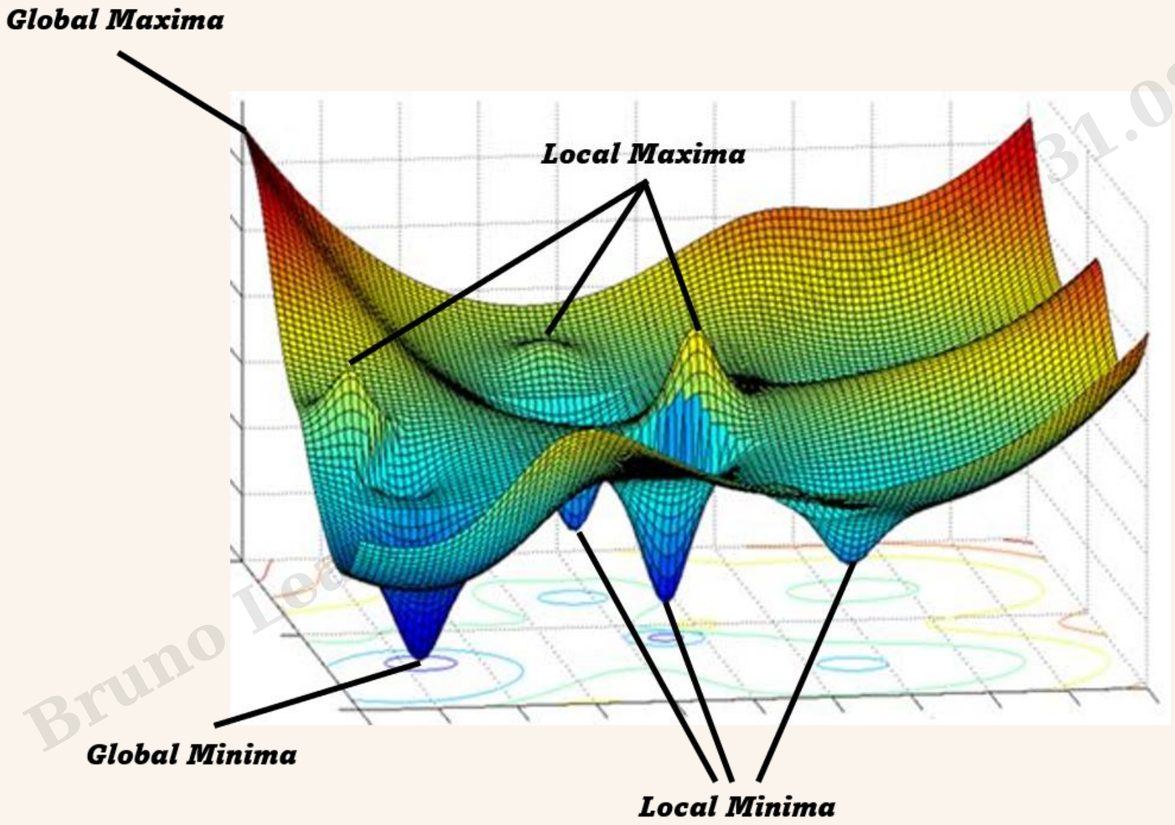
1. Tatear a direção de descida
2. Dar um pequeno passo para baixo
3. Repetir até não conseguir descer mais

Bruno Leandro Saraiva Ribeiro 931.087.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Nem todo vale é o mais baixo

A superfície de erro pode ter vários picos e vales — o algoritmo pode ficar preso em um mínimo local, sem alcançar o mínimo global.

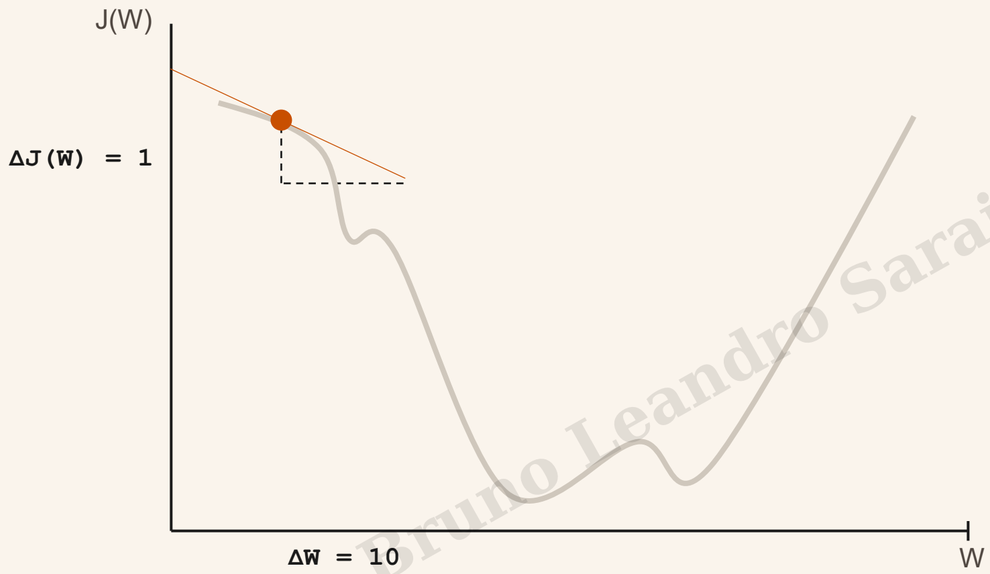


Bruno Leandro 431.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A derivada indica a direção

"Tatear" a direção de descida é calcular a derivada — a taxa de variação da loss J(W) em relação aos pesos W naquele ponto.



"Quando W varia 10, J(W) varia 1 " — a inclinação (derivada) naquele ponto é **0.1**.

Quanto maior a inclinação, mais íngreme o erro está variando naquele ponto — e maior o passo que o algoritmo dará.

Backpropagation: Algoritmo responsável por calcular a derivada dJ(W)/d(W)

Redes Neurais Pt. 2: Ideias principais de retropropagação

O que a retropropagação realmente está fazendo? | Capítulo 3, Aprendizado profundo

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Atualizando os pesos

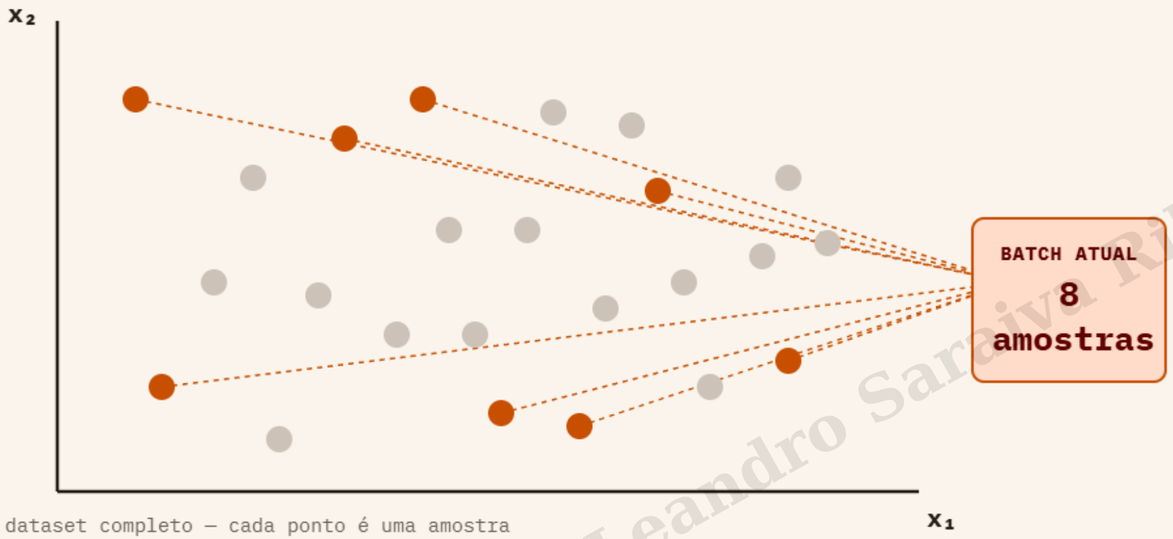
$$W_{próximo} = W_{atual} - \eta \cdot \nabla J(W)$$

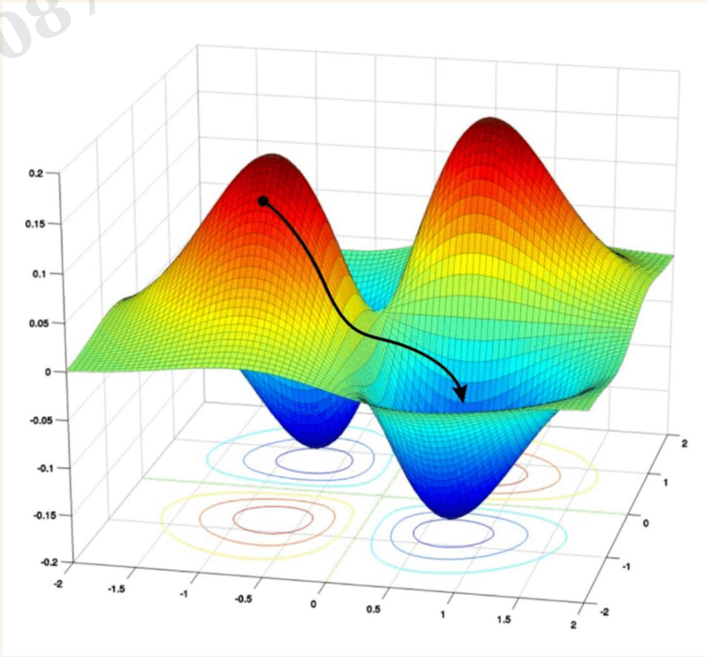
$W_{próximo}$	**W_{atual}**	**η (eta)**	**$\nabla J(W)$**
novos pesos	pesos atuais	taxa de aprendizagem	gradiente da loss

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Mini-batch Stochastic Gradient Descent





Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Mini-batch Stochastic Gradient Descent

POR QUE MINIBATCH?

- Aproveita a paralelização de GPU
- Acelera o treinamento substancialmente

IMPACTO DO BATCH SIZE

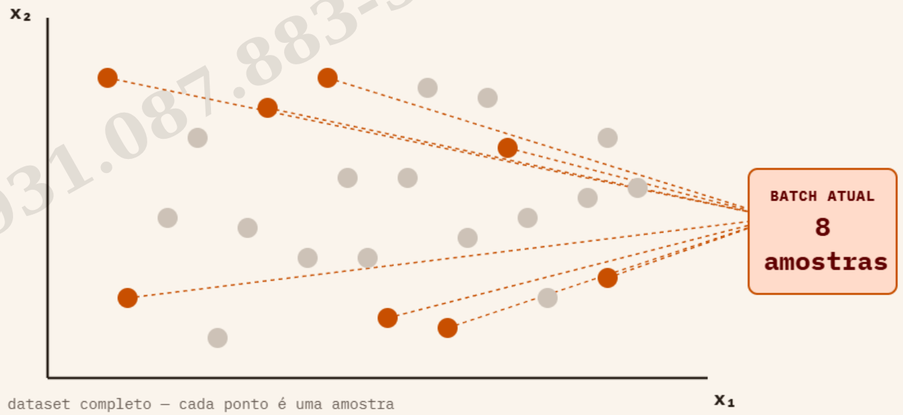
- Maior ⇒ treino mais rápido, porém mais memória
- Menor ⇒ ruído benéfico na superfície J(W), regularizando o modelo

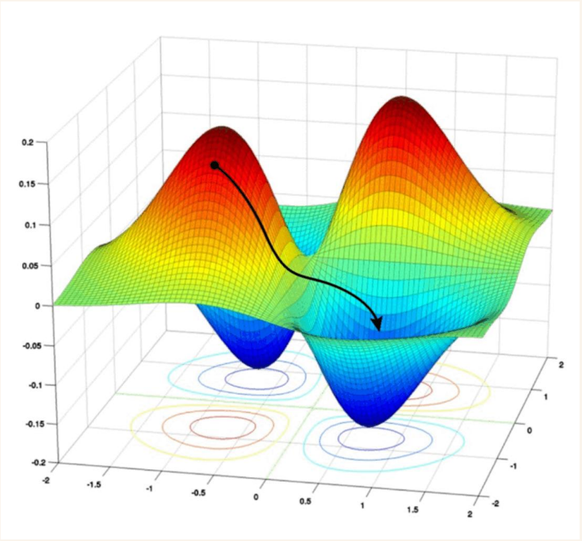
IMPACTO DO LEARNING RATE

- Define o tamanho do passo a cada atualização
- Maior é mais rápido e instável
- Pequeno demais estagna o treino em mínimos locais

Equilíbrio: a partir de um ponto basal estável, aumente batch size e learning rate pelo mesmo fator — `BS × K` e `LR × K`.

BS sempre em múltiplos de 8





Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Otimizadores

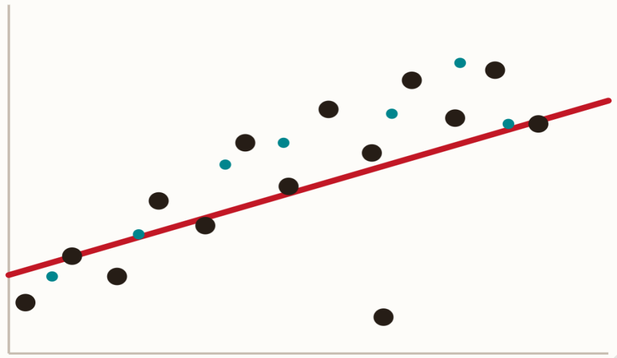
OTIMIZADOR	MELHOR PARA	PRÓS	CONTRAS
`SGD`	Modelos simples, memória baixa	Interpretável, estável	Convergência lenta
`SGD + Momentum`	Maioria das tarefas, com ajuste	Melhor convergência que SGD puro	Exige ajuste cuidadoso
`Adam`	Escolha padrão	Rápido, adaptativo	Pode overfittar sem regularização
`AdamW`	Transformers, modelos grandes	Weight decay desacoplado — melhor generalização que Adam	Mais um hiperparâmetro (decay) para ajustar
`RMSprop`	RNNs, RL	Bom para dados não-estacionários	Exige ajuste
`Adagrad`	Features esparsas	Ótimo para dados esparsos	Decaimento do learning rate
`Adadelta`	Taxas adaptativas sem ajuste manual	Sem necessidade de ajustar LR	Mais lento
`Nadam`	Modelos profundos	Momentum de Nesterov + Adam	Raramente melhor que Adam
`FTRL`	Modelos online esparsos e de larga escala	Regularização embutida	Não indicado p/ redes profundas

Bruno Leandro Saraiva Ribeiro 031.087.083-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

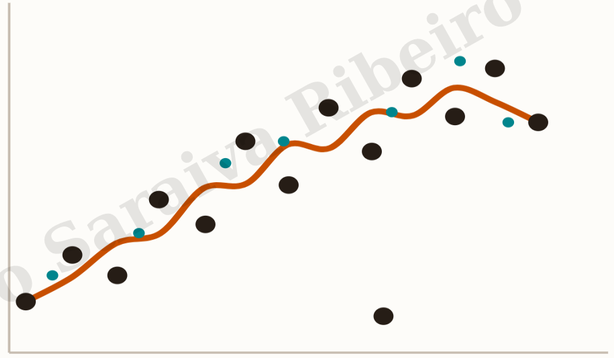
OTIMIZAÇÃO DO MODELO

Underfitting vs balanceado vs overfitting



Underfitting

Modelo simples não se adapta a curvatura da tendência real.



Balanceado

Modelo adequado acompanha a tendência, ignorando ruído e outlier.



Overfitting

Modelo superdimensionado memoriza cada ponto de treino, inclusive o outlier.

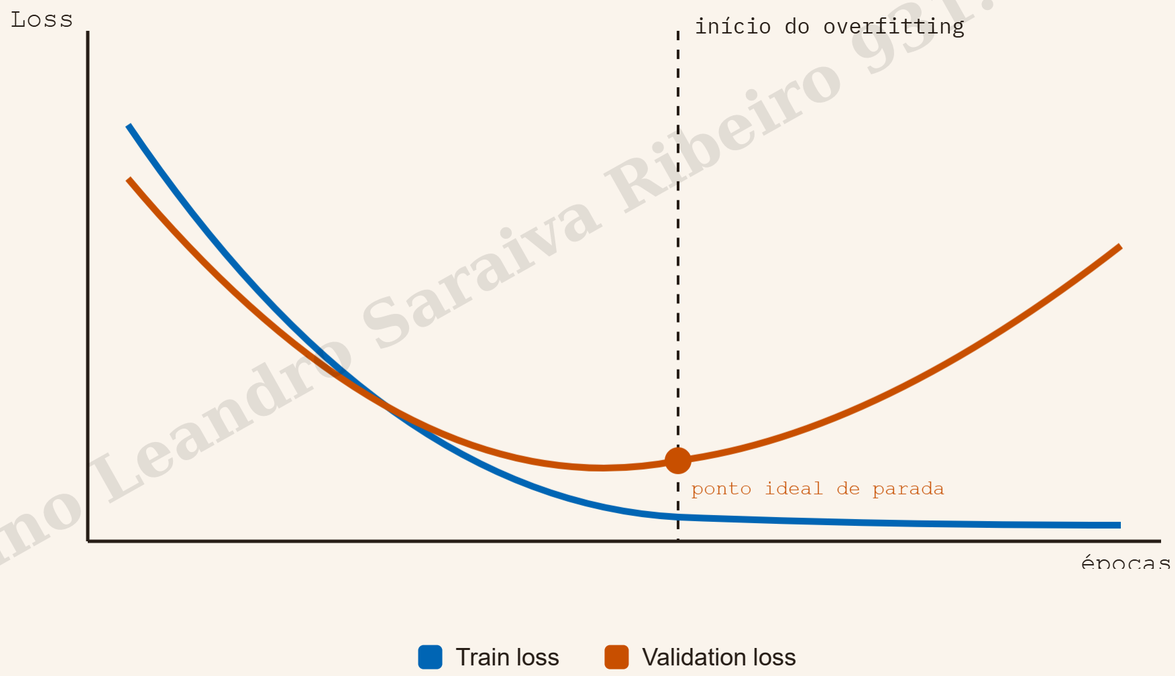
Treino Teste

Bruno Leandro Sarniva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Overfitting ao longo do treino

A loss de treino cai continuamente. A loss de validação cai junto — até o ponto em que o modelo passa a decorar o treino, e a loss de validação começa a subir. Restauramos o modelo da melhor época de validação.



Bruno Leandro Saraiva Ribeiro 931.087.883-53

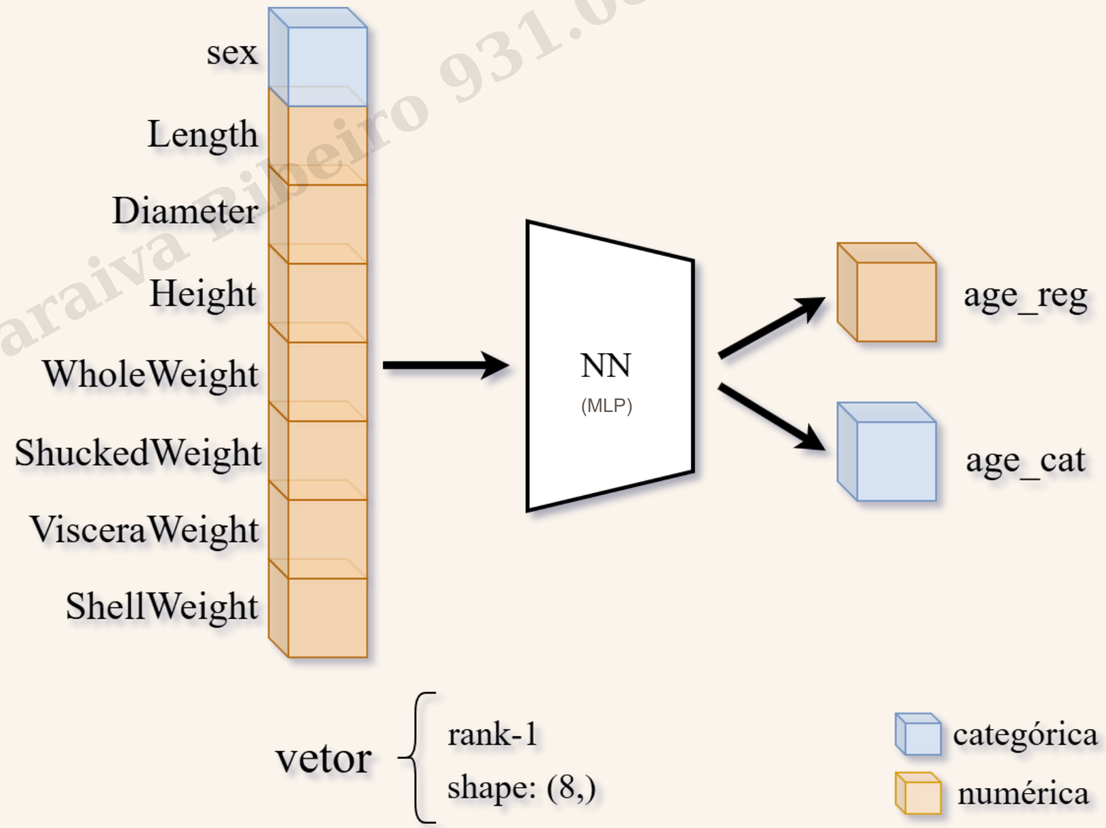
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Dataset Abalone — multi-task model

Abalone — UCI Machine Learning Repository. 8 features (categóricas + numéricas); target: idade do molusco.







Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Categorical Encoding

MÉTODO	SHAPE	ORDEM	COMPLEXIDADE	EXEMPLOS
`One-hot`	(N,) ou (N−1,)	Sem ordem	O(N)	Cor {azul, vermelho, verde}; Sexo {M, F, O}
`Label / Sparse`	(1,)	Sem ordem real (ids arbitrários)	O(1)	Target categórico {y_true}
`Ordinal`	(1,)	Com ordem genuína	O(1)	Escala Likert {1..5}; Escolaridade {grad, msc, phd}; Pipeline de etapas {Criado, pago, preparação, enviado, trânsito, …, entregue}
	⚠️ Exige ordem genuína, mas não espaçamento uniforme: a rede neural *aprende a aproximar* a distância *adequada* para a tarefa. ⚠️			
`Embedding`	(N, d)	Aprendida (similaridade)	O(d)	Categorias de alta cardinalidade em redes profundas

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Feature Scaling

MinMaxScaler

- Reescala para intervalo fixo [0,1]
- Preserva a distribuição; sensível a outliers

Ex.: pixels de imagens (0–255)

HISTOGRAMA



BOXPLOT

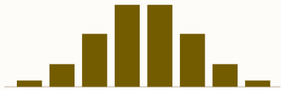


StandardScaler

- Centraliza para média 0, desvio 1
- Acelera convergência; distorce distribuições assimétricas

Ex.: altura, peso — dados ~normais (μ≈170cm, σ≈10)

HISTOGRAMA



BOXPLOT



RobustScaler

- Escalona pela mediana e IQR
- Resistente a outliers; bom para dados ruidosos

Ex.: renda ou preços, com outliers

HISTOGRAMA



BOXPLOT



MaxAbsScaler

- Escalona pelo valor absoluto máximo → [-1,1]
- Preserva esparsidade; ótimo para dados esparsos de alta dimensionalidade.

Ex.: matriz TF-IDF de texto

HISTOGRAMA



BOXPLOT



Normalizer

- Atua por amostra, não por feature
- Força a norma do vetor a 1 — foco na direção

Ex.: embeddings de texto/similaridade

HISTOGRAMA



BOXPLOT



PowerTransformer

- Aproxima distribuições assimétricas de uma Normal
- Box-Cox exige X>0; Yeo-Johnson aceita X≤0

Ex.: preços ou contagens de cauda longa

HISTOGRAMA



BOXPLOT



Bruno Leandro Saraiva Ribeiro 931.087.883-59

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

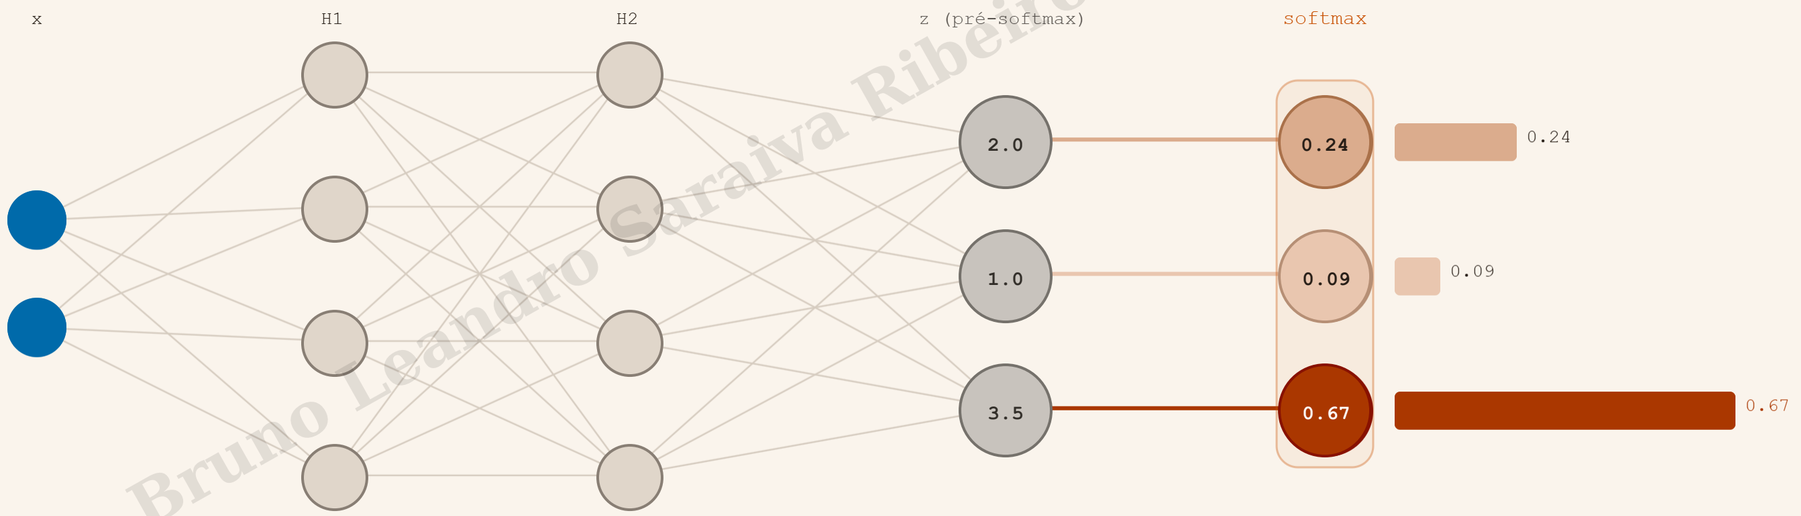
PRÁTICA GUIADA I

Ativação Softmax

$$S(z_i) = e^{z_i} / \Sigma_j e^{z_j}$$

Transforma um vetor de logits em uma **distribuição de probabilidade** — todos os valores somam 1.

Usada na camada de saída de problemas de classificação multiclasse.



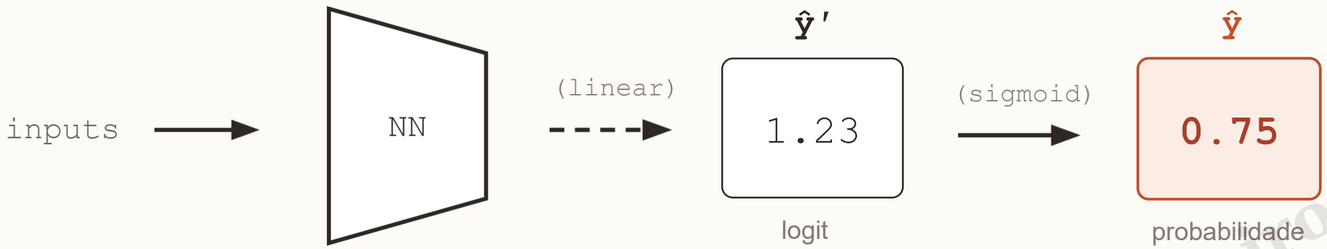
Bruno Leandro Saraiva Ribeiro 931.087.885-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Entropia Cruzada como Loss

Binary Cross Entropy · BCE



y = 1 rótulo verdadeiro — só pode ser **0** ou **1**

FÓRMULA

$$BCE = -\left[\, y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \,\right]$$

SUBSTITUINDO Y = 1 E Ŷ = 0.75

$$BCE = -\left[\, 1 \cdot \log(0.75) + (1 - 1) \cdot \log(1 - 0.75) \,\right]$$

$$BCE = -\left[\, \log(0.75) + 0 \,\right]$$

$$BCE = -\log(0.75) \approx 0.288$$

QUANDO USAR

Classificação **binária** (1 neurônio + sigmoid) ou **multirrótulo** , onde cada saída é independente.

INTUIÇÃO

Só um dos dois termos sobrevive: se **y = 1** , a perda é **−log(ŷ)**; se **y = 0**, é **−log(1 − ŷ)**.

Quanto mais a probabilidade da classe correta se aproxima de **1**, mais a perda tende a **0** . Uma predição confiante e *errada* é punida de forma explosiva.

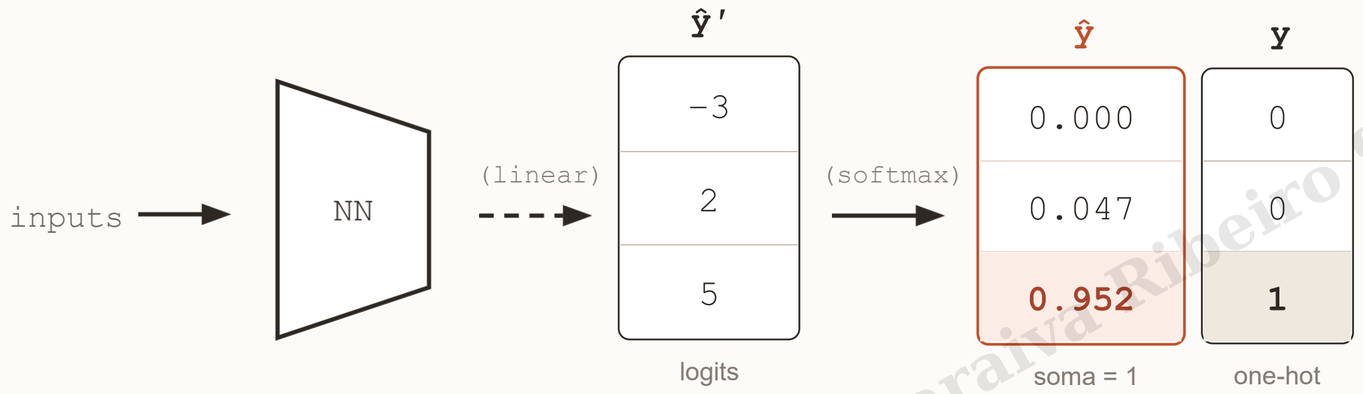
Bruno Leandro Saraiva Ribeiro 931.087.083-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Entropia Cruzada como Loss

Categorical Cross Entropy · CCE



FÓRMULA

$$CCE = -\sum_i y_i \cdot \log(\hat{y}_i)$$

TERMO A TERMO

classe	y	ŷ	y · log(ŷ)
0	0	0.000	0
1	0	0.047	0
2	**1**	**0.952**	**−0.049**

CCE = − (−0.049) **0.049**

ANTES DO SOFTMAX

Os logits assumem qualquer valor real, proporcionais à evidência acumulada para cada classe.

DEPOIS DO SOFTMAX

As saídas viram probabilidades correlacionadas entre si, somando exatamente 1.

QUANDO USAR

Se o **y true** está em **one-hot encoding** , a perda deve ser CCE.

Como o **y** é one-hot, todos os produtos zeram exceto o da classe correta: o somatório é, na prática, **um único termo**.

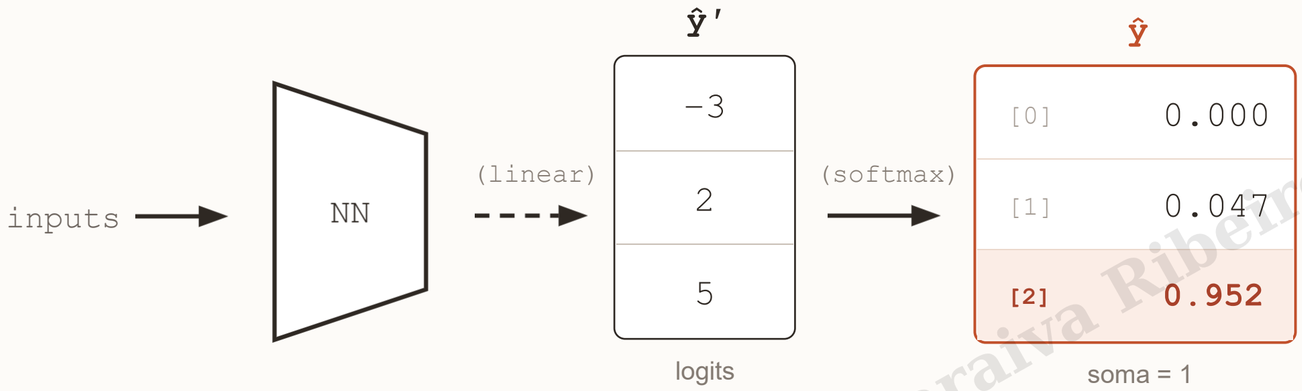
Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Entropia Cruzada como Loss

Sparse Categorical Cross Entropy · SCCE



y = 2 o rótulo é um **inteiro** — o índice da classe correta, não um vetor

FÓRMULA

$$SCCE = -\log(\hat{y}[y])$$

SUBSTITUINDO Y = 2

$$SCCE = -\log(\hat{y}[2]) = -\log(0.952)$$

SCCE = 0.049 — o mesmo valor da CCE

QUANDO USAR

Se o **y true** está em **inteiros** , a perda deve ser SCCE.

CUIDADO

Trocar a loss sem trocar o formato do rótulo é um dos erros mais comuns.

CCE OU SCCE?

	CCE	SCCE
rótulo	vetor one-hot	inteiro
memória	cresce com o nº de classes	constante, mesmo com muitas classes
na prática	métricas e rótulos suavizados	datasets grandes já indexados

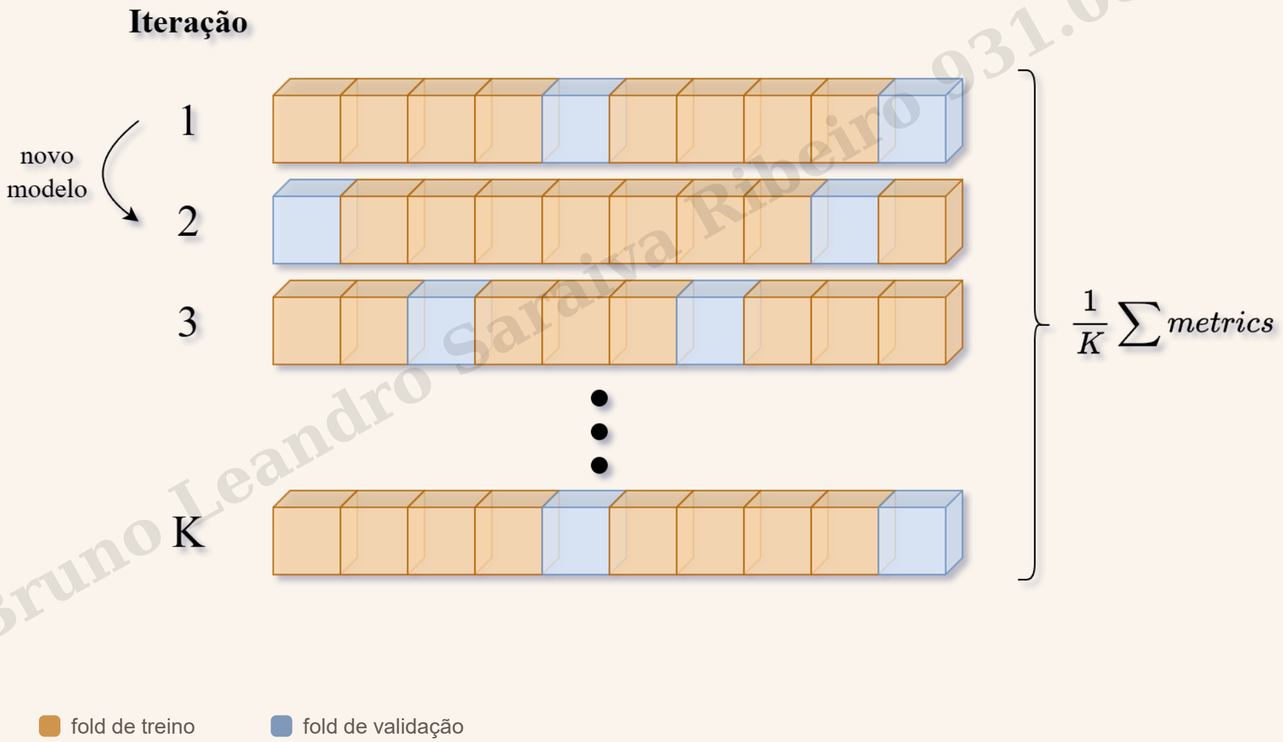
Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PRÁTICA GUIADA I

Repeated Cross-Validation

O dataset é dividido em K folds; cada rodada usa um fold diferente para validação. O processo se repete R vezes para uma estimativa mais robusta.



Bruno Leandro Saraiva Ribeiro 931.087.883-53

R rodadas × K folds — a estimativa final é a média e desvio das métricas de cada rodada.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARA SABER MAIS

Bibliografia e canais recomendados

LIVROS

Deep Learning with Python, 3ª ed. — François Chollet (Keras)

Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow, 3ª ed. — Aurélien Géron

Deep Learning with PyTorch, 2ª ed. — Eli Stevens

Hands-On Machine Learning with Scikit-Learn and PyTorch, — Aurélien Géron
(é uma "quarta" versão do anterior, atualizado e adaptado para pytorch)

DOCUMENTAÇÃO & CANAIS

Keras: Deep Learning for humans

PyTorch documentation — PyTorch 2.13 documentation

- AndrejKarpathy - Neural Networks - Zero to Hero
- But what is a neural network? | Deep learning chapter 1

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Prof. Luis Augusto Libório Oliveira Fonseca | https://www.linkedin.com/in/lsmliborio/

Bruno Leandro Saraiva Ribeiro 931.087.883-53

MBA USP ESALQ