MBA EM

DATA SCIENCE

Deep Learning e Inteligência Artificial III

Prof. Luis Augusto Libório Oliveira Fonseca

Bruno Leandro Saraiva Ribeiro - 031.087.883-53

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

MBA USP ESALQ

PROFESSOR

Prof. MSc. Luis Augusto Libório O. Fonseca



2018	Bacharel em Engenharia Mecatrônica, Unit
2021	Especialista em Mecatrônica, Unicamp
2022	MBA em Ciência de Dados, USP
2022	Mestre em Eng. Elétrica e Computação, Unicamp + Samsung
2023–24	Cientista em Machine Learning, Ford
2023–	Doutorando em Tecnologia, Unicamp
2024–	**Professor de pós-graduação**

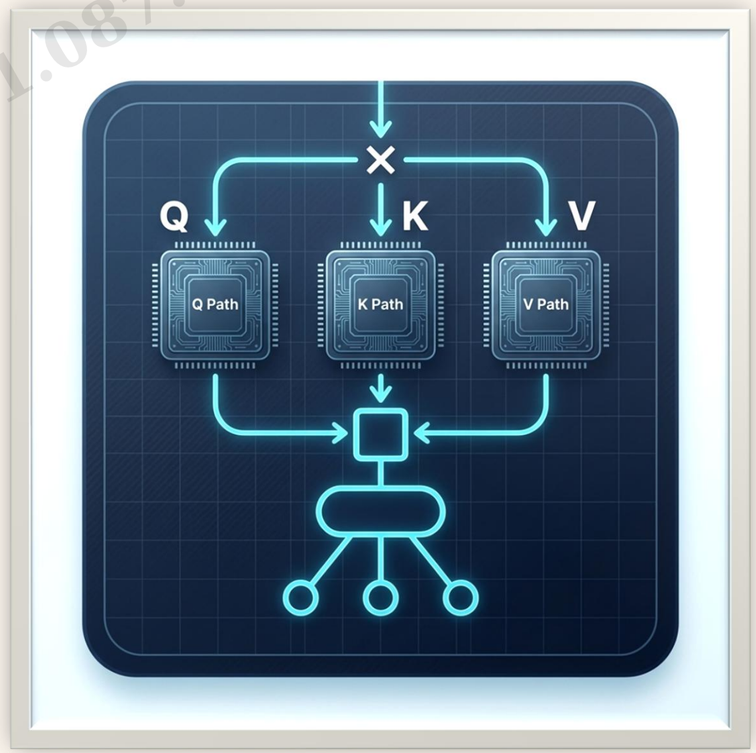
Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Conteúdo Programático

Depois das MLPs e das CNNs, chegamos ao texto: a sequência em que a ordem das palavras carrega o sentido.

1. Linguagem natural
2. Text to tensor
3. Bag-of-words
4. Word sequence e embedding
5. Transformer e atenção com positional encoding



Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARTE 1

Linguagem natural

Bruno Leandro Saraiva Barbeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

LINGUAGEM DE MÁQUINA VS NATURAL

A máquina não lê, ela conta

Como codificar a semântica a partir de um código tão ambíguo e flexível?

“Eu não gostei muito do filme, mas assisti até acabar.”

≈

“O filme inteiro foi sem graça.”

SOBREPOSIÇÃO DE PALAVRAS

Apenas **filme** aparece nas duas frases.

"QUEM DECIDE QUE O SENTIDO É O MESMO?"

R: O modelo. Mas antes o texto precisa ser **vetorizado**.

LINGUAGEM DE MÁQUINA

→ As regras vêm primeiro

Sintaxe fixa e sem ambiguidade: o que não cabe na gramática é rejeitado.

LINGUAGEM NATURAL

→ O uso vem primeiro

A gramática apenas descreve o que o uso consagrou.

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARTE 2

Text to tensor

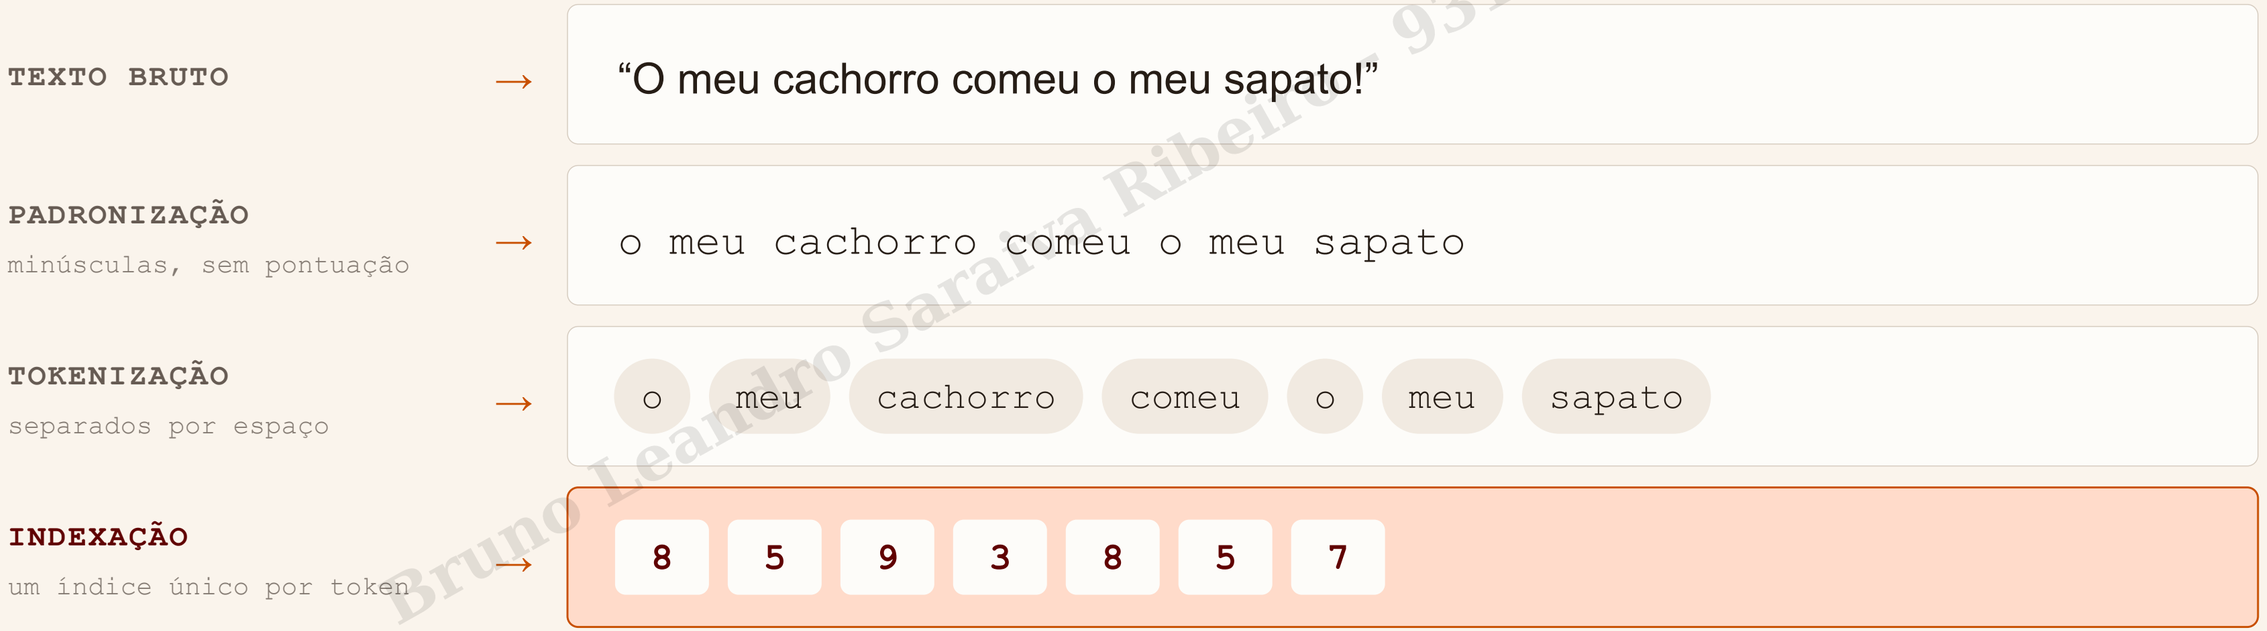
Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

TEXT ENCODING

Três decisões entre a frase e o tensor

Quanta informação preservamos na padronização, quão granular é o token e qual índice cada token recebe.



* tokens reservados: '' → 0 (padding), [UNK] → 1 (fora do vocabulário)

Bruno Leandro Saraiva Ribeiro - 931.087.883-55

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

As três decisões viram argumentos

A camada TextVectorization padroniza, tokeniza e indexa dentro do próprio modelo.

```python
from keras.layers import TextVectorization

vectorizer = TextVectorization(
    max_tokens=20000,
    standardize="lower_and_strip_punctuation",
    split="whitespace",
    output_mode="int",
    output_sequence_length=7,
)

vectorizer.adapt(textos_de_treino)     # corpus de treino
vectorizer(["o meu cachorro comeu o meu sapato"])
# [[8, 5, 9, 3, 8, 5, 7]]
```

MAX_TOKENS

O tamanho do vocabulário: os 20000 tokens mais frequentes.

OUTPUT_SEQUENCE_LENGTH

Toda sequência sai com o mesmo comprimento: corta ou completa com 0.

ADAPT()

O vocabulário é aprendido **só** nos dados de treino.

* tokens reservados: '' → 0 (padding), [UNK] → 1 (fora do vocabulário)

Marcio Leandro Saraiva Ribeiro - 937.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

TIPOS DE VETORIZAÇÃO

O que cada encoding preserva

Ordem, frequência e semântica são as três informações em disputa. Cada escolha muda o shape e tipo do tensor.

ENCODING	ORDEM	FREQUÊNCIA	SEMÂNTICA	SHAPE	DTYPE
N-gram multi-hot	não	não	não	(vocab,)	binário
N-gram TF-IDF	não	sim	não	(vocab,)	float
Sequence one-hot	sim	sim	não	(s, vocab)	binário
Sequence embedding	sim	sim	sim	(s, d)	float

Bruno Leandro Sarsiva Ribeiro - 931.087.883-53

→ Quanto mais informação preservada, maior o **potencial** de aprendizado. Mas mais difícil se torna a tarefa.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARTE 3

Bag-of-words

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

N-GRAM MULTI-HOT ENCODING

Um saco de tokens, sem ordem

O vetor marca apenas quais tokens do vocabulário apareceram (a posição e a contagem se perdem).

FRASE `o meu cachorro comeu o meu sapato`

N = 1	`o` `meu` `cachorro` `comeu` `sapato`
N = 2 + os 1-grams	`o meu` `meu cachorro` `cachorro comeu` `comeu o` `o meu` `meu sapato`

VETOR MULTI-HOT 1-GRAM (VOCAB = 10)

0	''	0
1	[UNK]	0
2	gato	0
3	**comeu**	**1**
4	bola	0
5	**meu**	**1**
6	roeu	0
7	**sapato**	**1**
8	**o**	**1**
9	**cachorro**	**1**

- Tokens são sequências de **até** N unidades adjacentes.
- Não há ordem entre tokens, apenas **dentro** do token quando N > 1.
- Não há informação de frequência: só presença.

→ "o meu cachorro comeu o meu sapato" e "o meu sapato comeu o meu cachorro" dão o **mesmo** vetor.

Bruno Leandro Saraiva Ribeiro - 031.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

N-GRAM TF-IDF ENCODING

Pesar cada token pela sua raridade

Term Frequency × Inverse Document Frequency: frequente na sentença, raro no corpus => então é informativo.

$$\text{tf-idf}(t, d) = \underbrace{\text{tf}(t, d)}_{\text{vezes que t aparece em d}} \cdot \underbrace{\log(N / \text{df}(t))}_{\text{quantos documentos contêm t}}$$

TOKEN	TF	DF	TF-IDF
o	2	9 800	0.04
meu	2	4 100	0.78
cachorro	1	120	**4.42**
sapato	1	340	3.38

O QUE GANHAMOS

Palavras muito comuns deixam de dominar o vetor.

O QUE CONTINUA FALTANDO

A ordem em longo prazo e qualquer noção de significado.

* valores simulados para fins didáticos (N = 10 000 documentos)

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARTE 4

Word Sequence e Embeddings

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SEQUENCE ONE-HOT ENCODING

Preservando a ordem, o custo explode

Cada token vira um vetor OHE. A sequência é preservada, mas o tensor fica esparso.

	0	1	2	3	4	5	6	7	8	9
o	0	0	0	0	0	0	0	0	**1**	0
meu	0	0	0	0	0	**1**	0	0	0	0
cachorro	0	0	0	0	0	0	0	0	0	**1**
comeu	0	0	0	**1**	0	0	0	0	0	0
o	0	0	0	0	0	0	0	0	**1**	0
meu	0	0	0	0	0	**1**	0	0	0	0
sapato	0	0	0	0	0	0	0	**1**	0	0

SHAPE

(s, vocab)

7 × 20000 = 140000 valores

PRESERVA

Ordem e frequência dos tokens.

LIMITAÇÃO

Todos os tokens ficam à mesma distância: **nenhuma** semântica.

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

WORD EMBEDDING

De esparso e binário a denso e treinável

Em vez de uma dimensão por palavra, poucas dimensões contínuas onde a distância significa algo.

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

ESPARSO · ONE-HOT

"cachorro"



- 20000 dimensões, uma por palavra
- valores fixos, nada a aprender
- "cachorro" e "gato" tão distantes quanto "cachorro" e "sapato"

→

embedding (d = 4)

DENSO · EMBEDDING

"cachorro"



- d dimensões arbitrárias, tipicamente 8 a 512
- pesos treináveis, iniciados aleatoriamente
- palavras de uso parecido acabam próximas

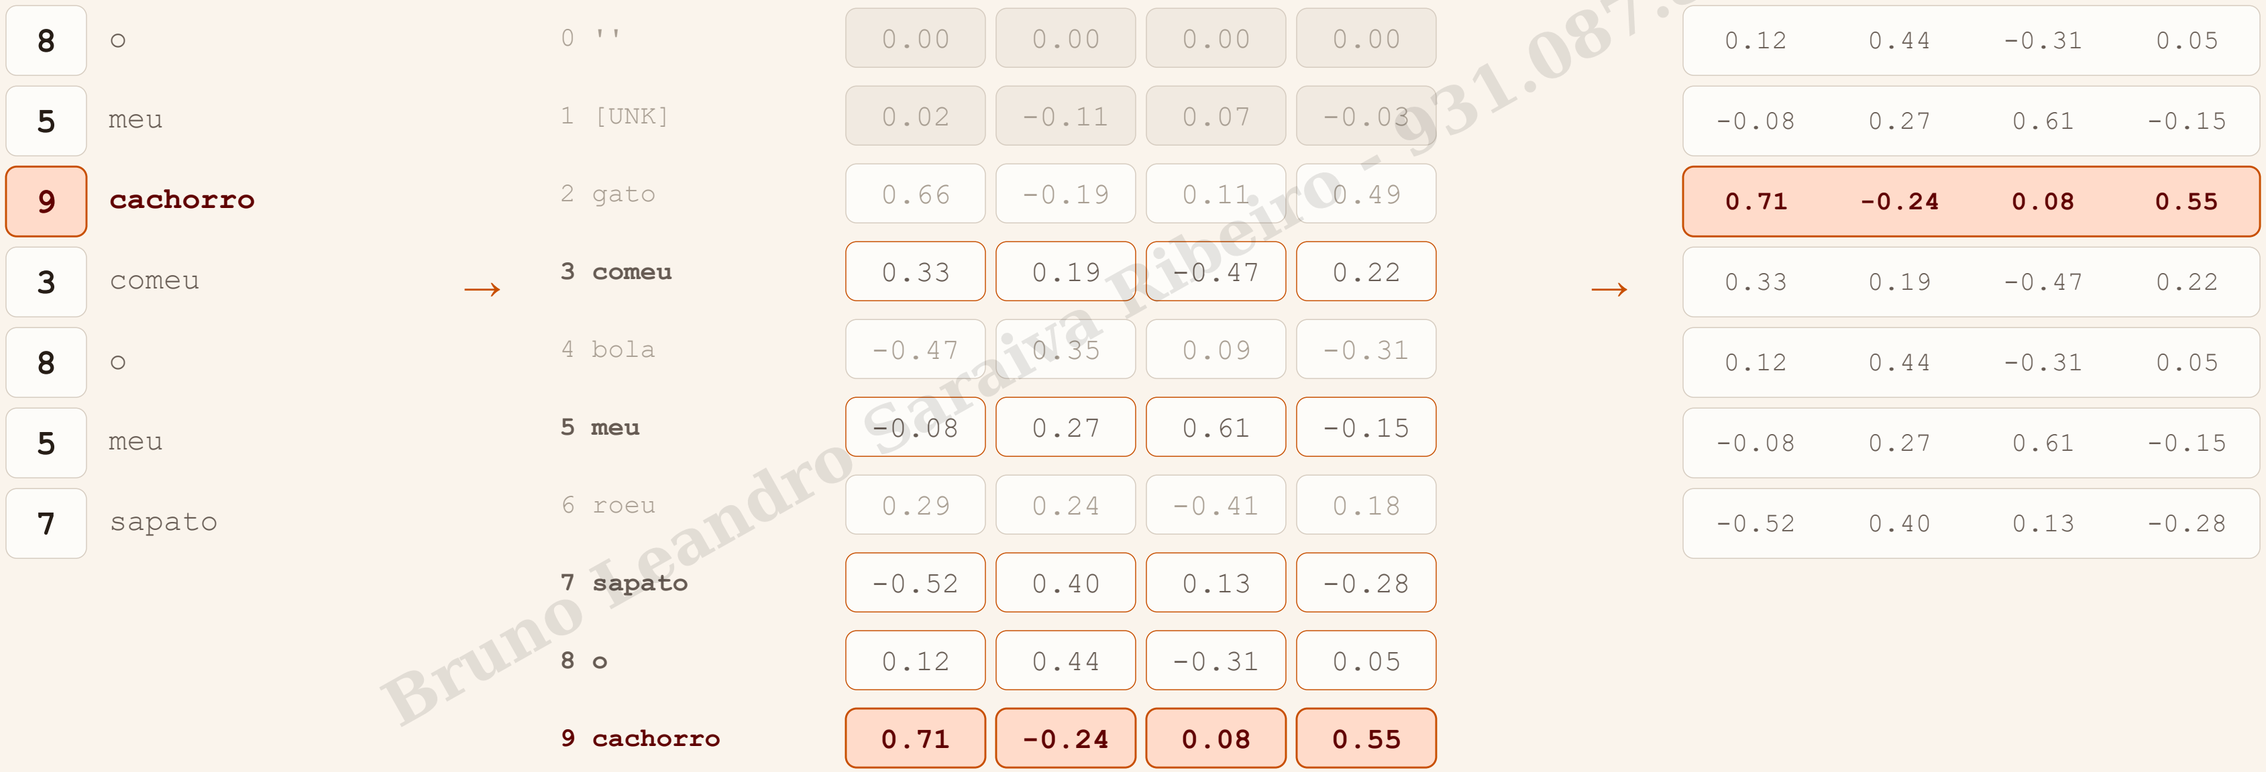
* valores reais são aprendidos no treino

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

WORD EMBEDDING

O índice seleciona uma linha da matriz

A frase é montada a partir do vocabulário: cada índice devolve a sua linha de pesos treináveis.



* vocabulário reduzido a 10 tokens para caber na tela; "o" e "meu" repetem na frase e consultam a mesma linha

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

EMBEDDING LAYER KERAS

Uma camada, dois números

O tamanho do vocabulário entra, a dimensão do vetor sai. Os pesos aprendem de acordo com a tarefa.

```python
import keras

inputs = keras.Input(shape=(max_seq_len,), dtype="int32")

x = keras.layers.Embedding(
    input_dim=20000,    # vocabulário
    output_dim=8,       # d
    mask_zero=True,     # ignora padding
)(inputs)

# x.shape == (batch, 7, 8)
```

PARÂMETROS TREINÁVEIS

20000 × 8 = 160000

QUANTO MAIOR d

Maior densidade de informação por token e mais dados necessários para treinar.

O QUE AINDA FALTA

O vetor de "banco" é o mesmo em toda frase: falta **contexto**.

* Bengio et.al. 2003 - doi: 10.1162/153244303322533223
* Word2Vec Mikolov et.al. 2013 - doi: 10.48550/arXiv.1301.3781

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARTE 5

Transformer

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SELF-ATTENTION: ENCONTRAR SENTIDO EM SI MESMO

Qual a relação entre todas as palavras?

O mesmo token tem sentidos diferentes em frases diferentes. O vetor precisa depender do contexto → "*transformar-se*".

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

FRASE 1	sentamos no **banco** da praça
FRASE 2	abrimos conta no **banco** da esquina
EMBEDDING FIXO	`emb("banco") = [0.71 -0.24 0.08 0.55]` o mesmo vetor nas duas frases

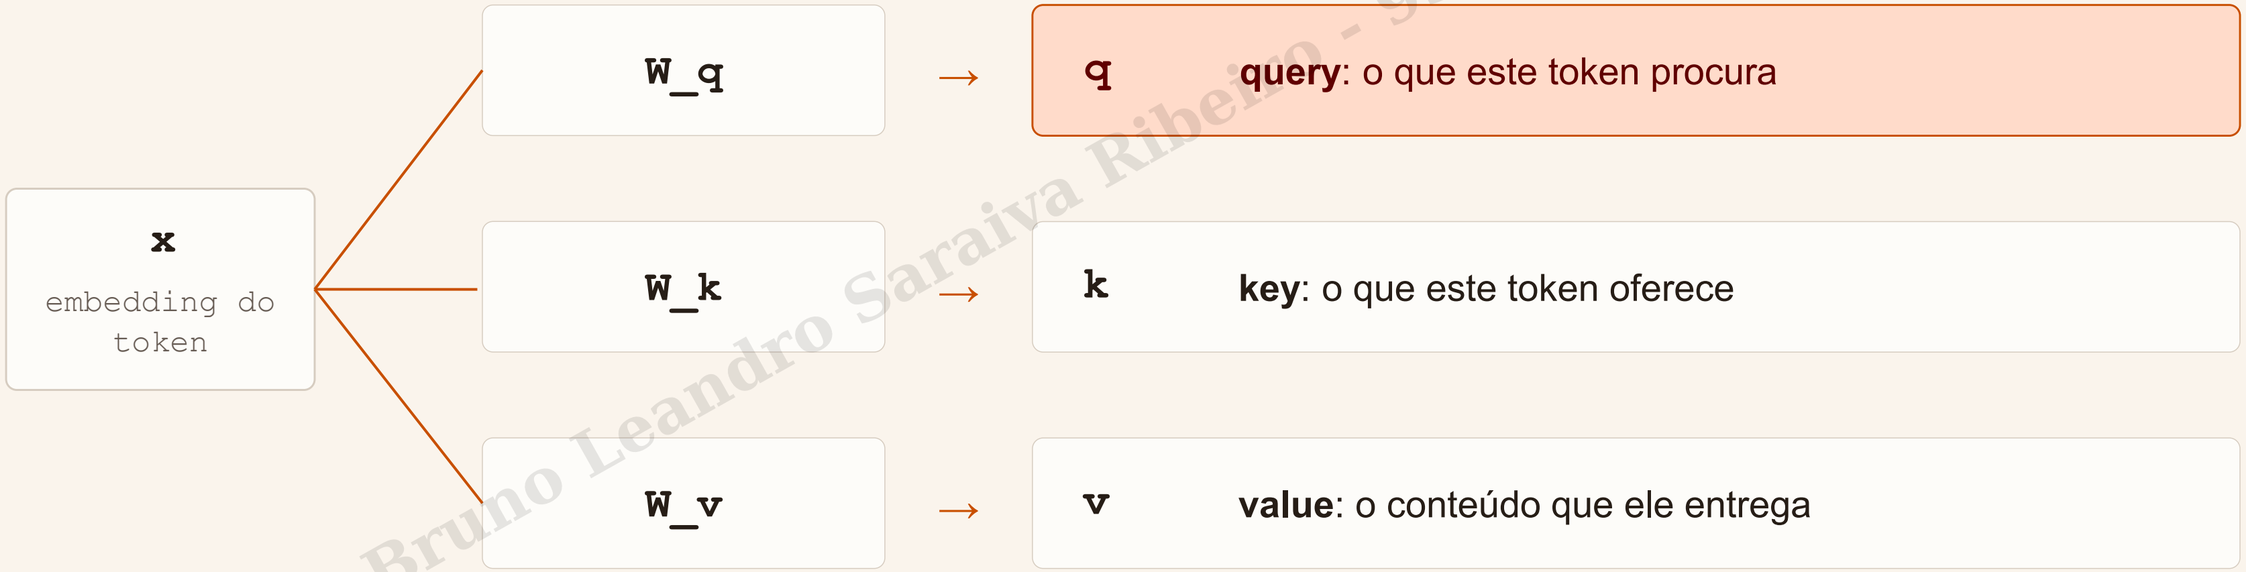
→ O mecanismo de *self-attention* reescreve *(transforma)* cada vetor como uma **mistura** dos vetores da própria frase.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SELF-ATTENTION: X => {Q, K, V}

Cada token gera três vetores

Três matrizes de pesos treináveis projetam o mesmo embedding em query, key e value.



Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Comparar, normalizar, misturar

Todo o mecanismo de atenção cabe em três operações aplicadas a cada token da sequência.

Bruno Leandro Sarara Ribeiro - 931.087.883-53

1 COMPARAR

$$score(i, j) = k_j \cdot q_i$$

O produto escalar mede quanto o token **j** interessa ao token **i**.

s × s comparações

→

2 NORMALIZAR

$$s(i, j) = softmax_j(score / \sqrt{d})$$

Os scores de cada token viram pesos que **somam 1**.

√d mantém a escala estável

→

3 MISTURAR

$$y_i = \Sigma_j \; s(i, j) \cdot v_j$$

A saída é a **média ponderada** dos values da frase.

y tem o contexto embutido

* omitimos máscaras e a projeção final de saída para manter o foco no mecanismo

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SELF-SCORES MATRIX (S, S)

Uma linha de pesos por token

Cada linha diz quanto aquele token olha para os demais. Soma 1 depois do softmax.

	o	cachorro	comeu	o	sapato
o	**0.49**	**0.35**	0.07	0.05	0.04
cachorro	0.14	**0.50**	**0.26**	0.04	0.06
comeu	0.06	**0.26**	**0.41**	0.04	**0.23**
o	0.05	0.08	0.07	**0.48**	**0.32**
sapato	0.04	0.17	**0.27**	0.10	**0.42**

menor maior peso de atenção depois do softmax

A DIAGONAL

Cada token olha primeiro para si mesmo.

OS PARES DO VERBO

comeu divide a atenção entre **cachorro** e **sapato**.

E A VOLTA

sapato também olha para **cachorro**.

CADA LINHA SOMA 1

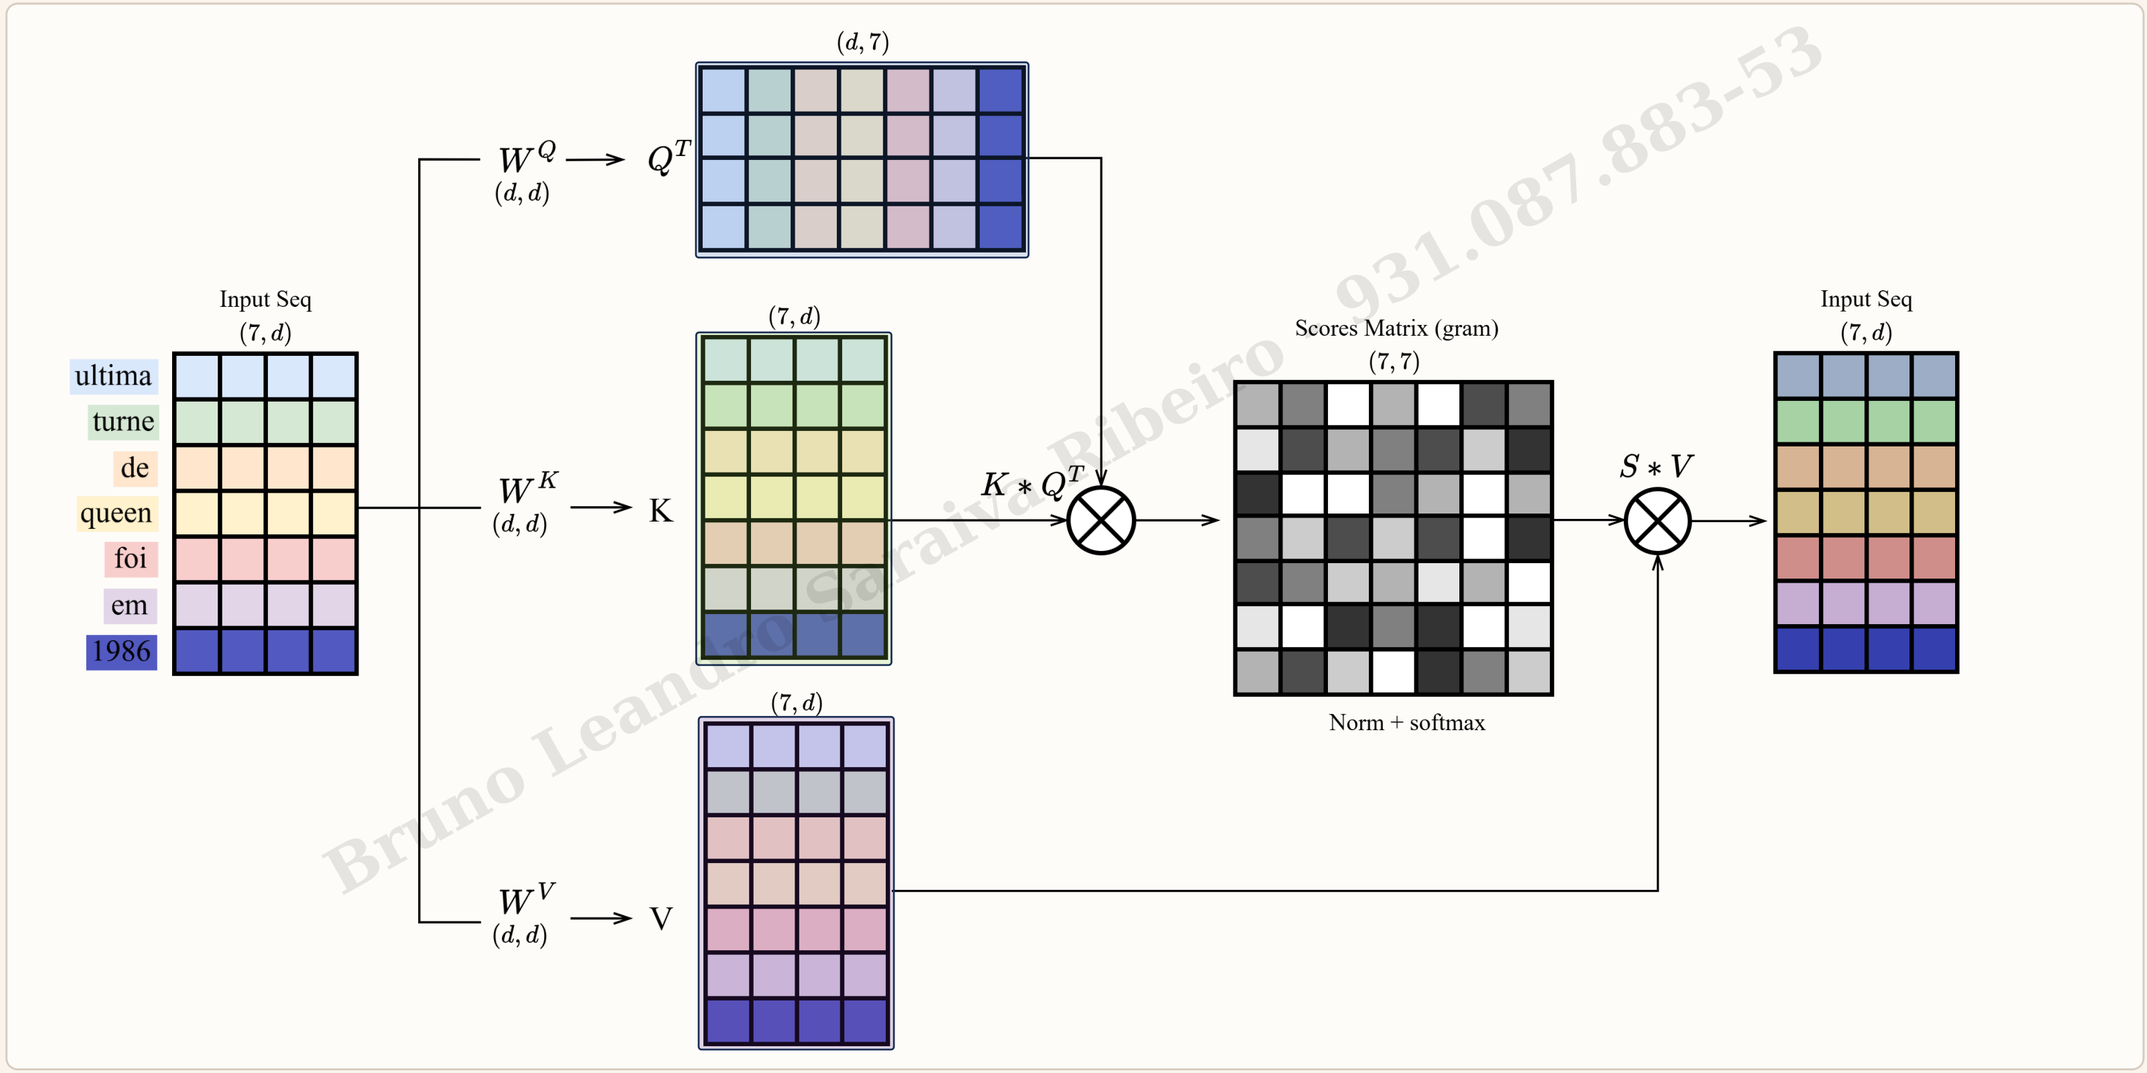
Efeito do softmax por linha.

* pesos simulados para fins didáticos; cada linha soma 1

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A cabeça de atenção por dentro



Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

POSITIONAL ENCODING

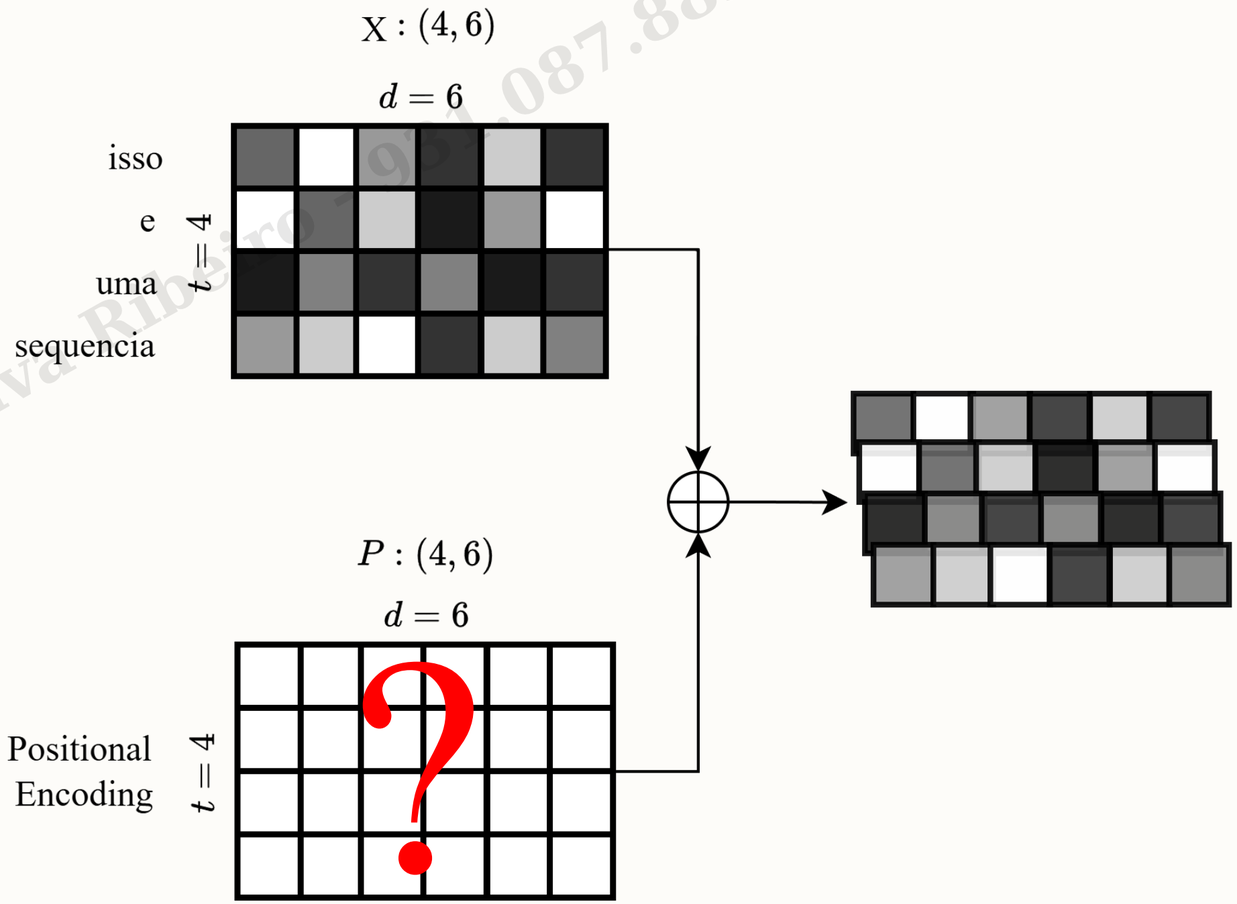
A atenção não sabe a ordem

Como todos os tokens são comparados ao mesmo tempo, a posição precisa ser somada ao vetor.

PREMISSAS DO SINAL DE POSIÇÃO

1. Não ambíguo: uma posição, um valor
2. Determinístico: vem de uma equação fixa
3. Mensurável: distâncias comparáveis
4. Expansível: vale para sequências mais longas
5. Estável em todas as dimensões

PE(pos, i) = ?



Bruno Leandro Saraiva Ribeiro - 951.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

POSITIONAL ENCODING

A atenção não sabe a ordem

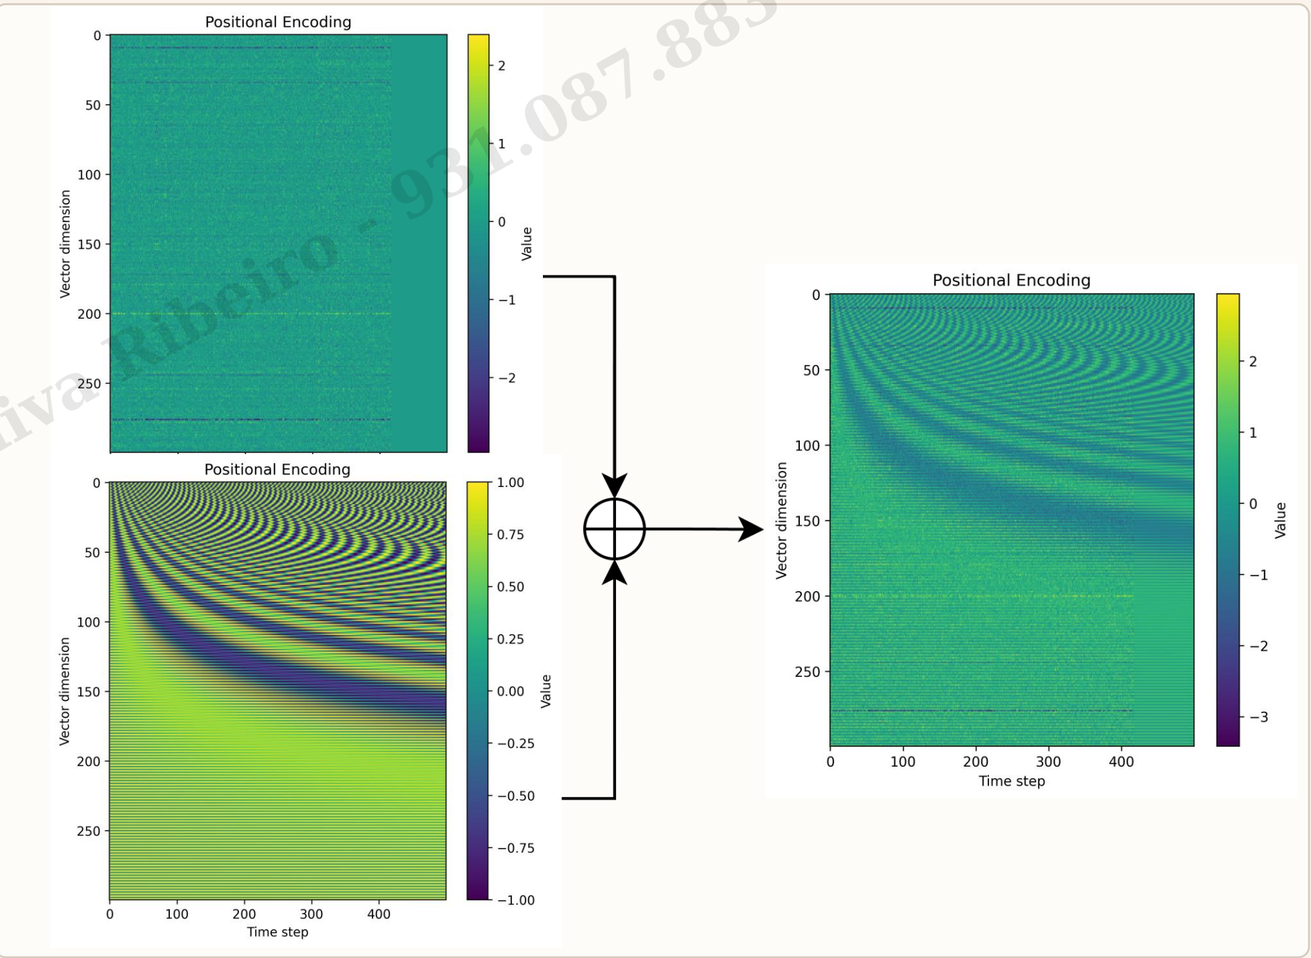
Como todos os tokens são comparados ao mesmo tempo, a posição precisa ser somada ao vetor.

PREMISSAS DO SINAL DE POSIÇÃO

1. Não ambíguo: uma posição, um valor
2. Determinístico: vem de uma equação fixa
3. Mensurável: distâncias comparáveis
4. Expansível: vale para sequências mais longas
5. Estável em todas as dimensões

$$PE(pos, 2i) = \sin(pos / 10000^{(2i/d)})$$

$$PE(pos, 2i+1) = \cos(pos / 10000^{(2i/d)})$$



Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

LSTM VS TRANSFORMER

Nem toda sequência pede atenção

A recorrência continua competitiva onde a sequência é longa, contínua e o orçamento é pequeno.

CRITÉRIO	LSTM	TRANSFORMER
Complexidade	Linear: O(N)	Quadrática: O(N²)
Paralelização no treino	Não: sequencial	Sim: todos os tokens
Relações de longo prazo	Limitada: esquece	Todos os pares conectados
Volume de dados exigido	Baixo / médio	Altíssimo
Memória na inferência	Baixa e constante	Alta e crescente
Casos de uso	Time series, IoT, áudio de baixa latência	LLMs, VLMs, tradução

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARA SABER MAIS

Bibliografia e canais recomendados

LIVROS E ARTIGOS

Deep Learning with Python , 3ª ed., François Chollet (cap. de NLP)

Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow , 3ª ed., Aurélien Géron

Attention Is All You Need, Vaswani et al. (2017), arXiv:1706.03762

Natural Language Processing with Transformers, Tunstall, von Werra & Wolf

DOCUMENTAÇÃO & CANAIS

Hugging Face: **NLP Course** e documentação de tokenizers

Andrej Karpathy: **Let's build GPT: from scratch**

3Blue1Brown: **Attention in transformers**, capítulos 5 e 6

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Prof. Luis Augusto Libório Oliveira Fonseca | https://www.linkedin.com/in/lsmliborio/

Bruno Leandro Saraiva Ribeiro - 931.087.883-53

MBA USP ESALQ