MBA EM

DATA SCIENCE

SVM – Support Vector Machines

Prof. Dr. Wilson Tarantin Junior

Bruno Leandro Saraiva Ribeiro 931.087.883-53

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Bruno Leandro Saraiva Ribeiro 931.087.883-53

MBA USP ESALQ

Support Vector Machines (SVM)

- **Quando aplicar o modelo?**

  - Aplicaremos em análises supervisionadas: Y = f(X) → inferência para novas observações
    - Comumente utilizado para tarefas de classificação: variável dependente categórica
    - Também pode ser utilizado para tarefas de regressão: variável dependente métrica

  - O SVM pode implementar classificações e regressões **lineares** ou **não lineares**
    - Destaca-se por ser um modelo flexível para lidar com dados de diversas características

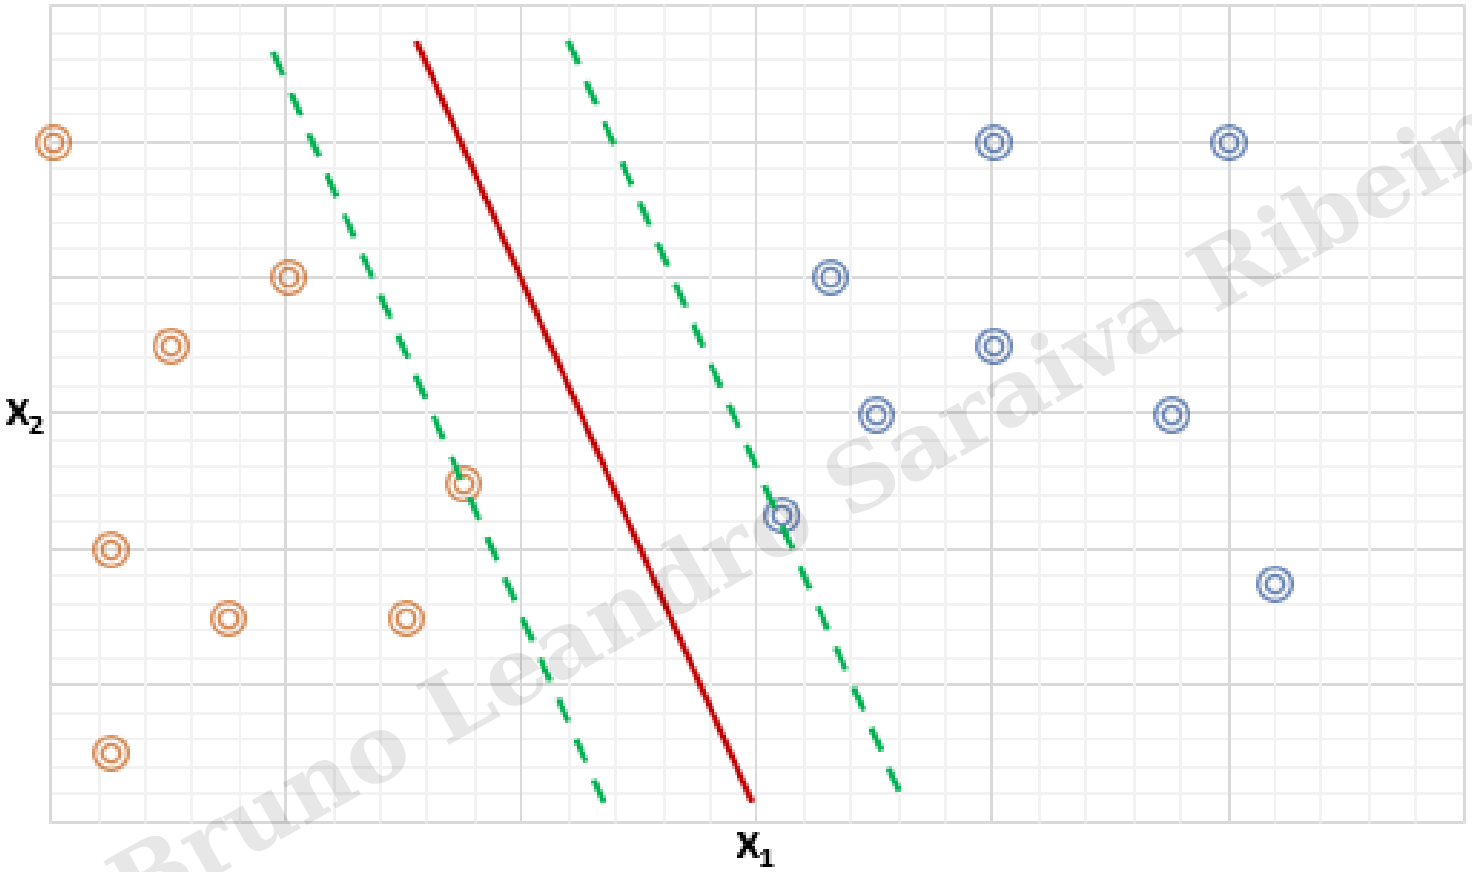
  - Pode lidar bem com bancos de dados de pequeno e médio porte
    - Em bases de dados muito grandes, pode ser computacionalmente custoso

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Linear

- **O objetivo geral é encontrar a fronteira de decisão que melhor separe as classes de Y**



- Na ilustração, há duas classes em Y indicadas por pontos azuis e laranjas
- Há separabilidade linear entre classes
- A linha em vermelho é a **fronteira de decisão** (hiperplano para muitas X)
  - As observações sobre as linhas pontilhadas são **vetores de suporte** (são observações que determinam a posição da fronteira de decisão)
  - A fronteira de decisão está o mais distante possível dos vetores. Linhas pontilhadas mostram as **margens**

Bruno Leandro Saraiva Ribeiro 031.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Linear

- **Aspectos adicionais sobre o modelo**

  - Na ilustração, os dados eram linearmente separáveis com base nas variáveis X e a separação foi perfeita (não houve a violação das margens). Frequentemente, isso não ocorre nos dados!

  - Problema de otimização do SVM: (i) maximiza a margem entre as classes, isto é, a distância entre a fronteira de decisão e os limites da margem; (ii) incorpora ao problema um termo que penaliza as violações da margem (as observações dentro da margem ou do lado errado da fronteira de decisão). Ao permitir tais violações, é chamado de SVM "*soft margin*"

  - Hiperparâmetro do modelo:
    - **C**: penalização atribuída às observações que violam a margem. Menores valores de C tendem a gerar margens maiores, pois a penalização imposta às violações é menor!
      - Valores altos de C podem levar ao *overfitting* (tendem a gerar modelos mais complexos)

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear

- **Classificação Não Linear**

  - Quando não há a separabilidade linear no espaço original das variáveis explicativas (X)

  - O SVM pode obter uma fronteira de decisão não linear

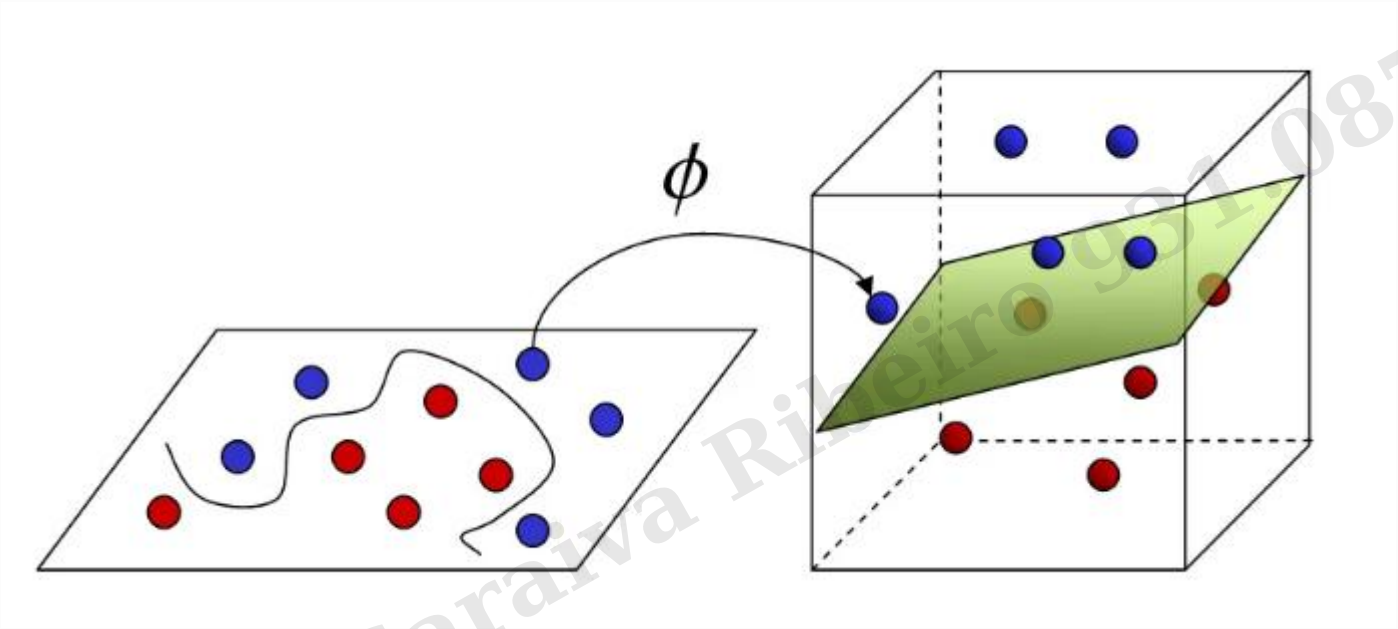
    - Os dados originais (X) são transformados para um novo espaço no qual as observações são comparadas; nova dimensão dos dados onde pode ocorrer a separabilidade linear

    - O SVM aplica uma função (“kernel”) que mapeia os dados e obtém as similaridades entre os pares de observações no espaço transformado; é utilizado como base no problema de otimização que busca maximizar a margem e limitar violações para obter um hiperplano que melhor separa as classes de Y

Bruno Leandro Soriva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear



Fonte: https://medium.com/

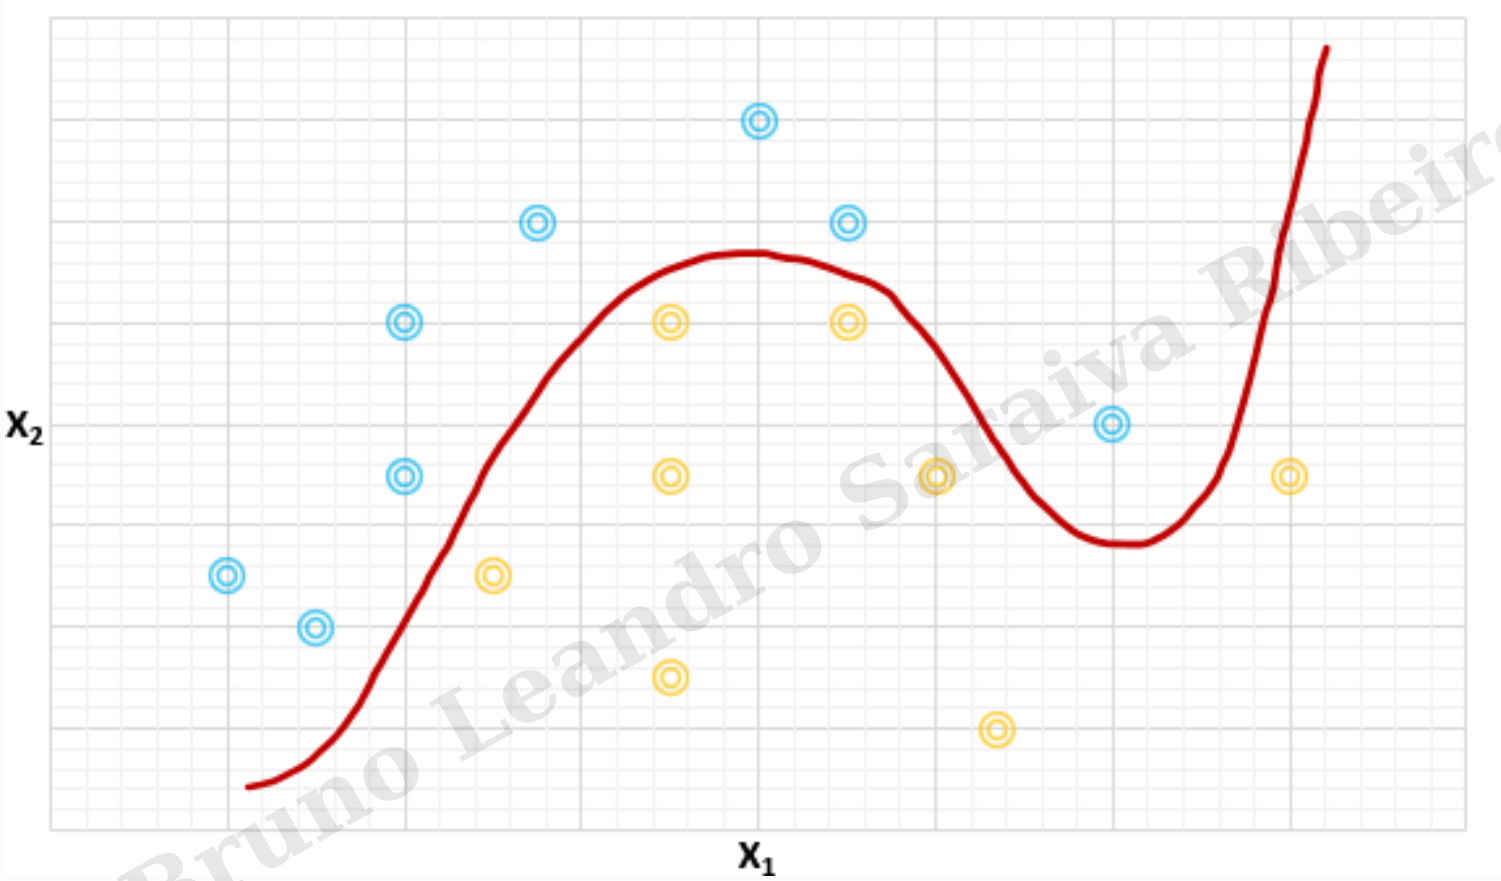
- Truque do kernel: não é necessário obter as coordenadas das observações no espaço transformado; o kernel calcula as similaridades das observações no novo espaço
- **Kernels não lineares recorrentemente utilizados: Polinomial e RBF (*Radial Basis Function*)**

Bruno Leandro Saraiva Ribeiro 961.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear

- **Ilustração de uma solução polinomial**



- **Kernel Polinomial**
- $K(a, b) = (\gamma\, a^T b + r)^d$
  - ***a*** **e** ***b*** **são duas observações**

- Substituindo os valores para ***a*** e ***b*** no kernel, obtém-se a relação de similaridade entre as observações proveniente do espaço transformado (como se tivesse adicionado características polinomiais das variáveis X)

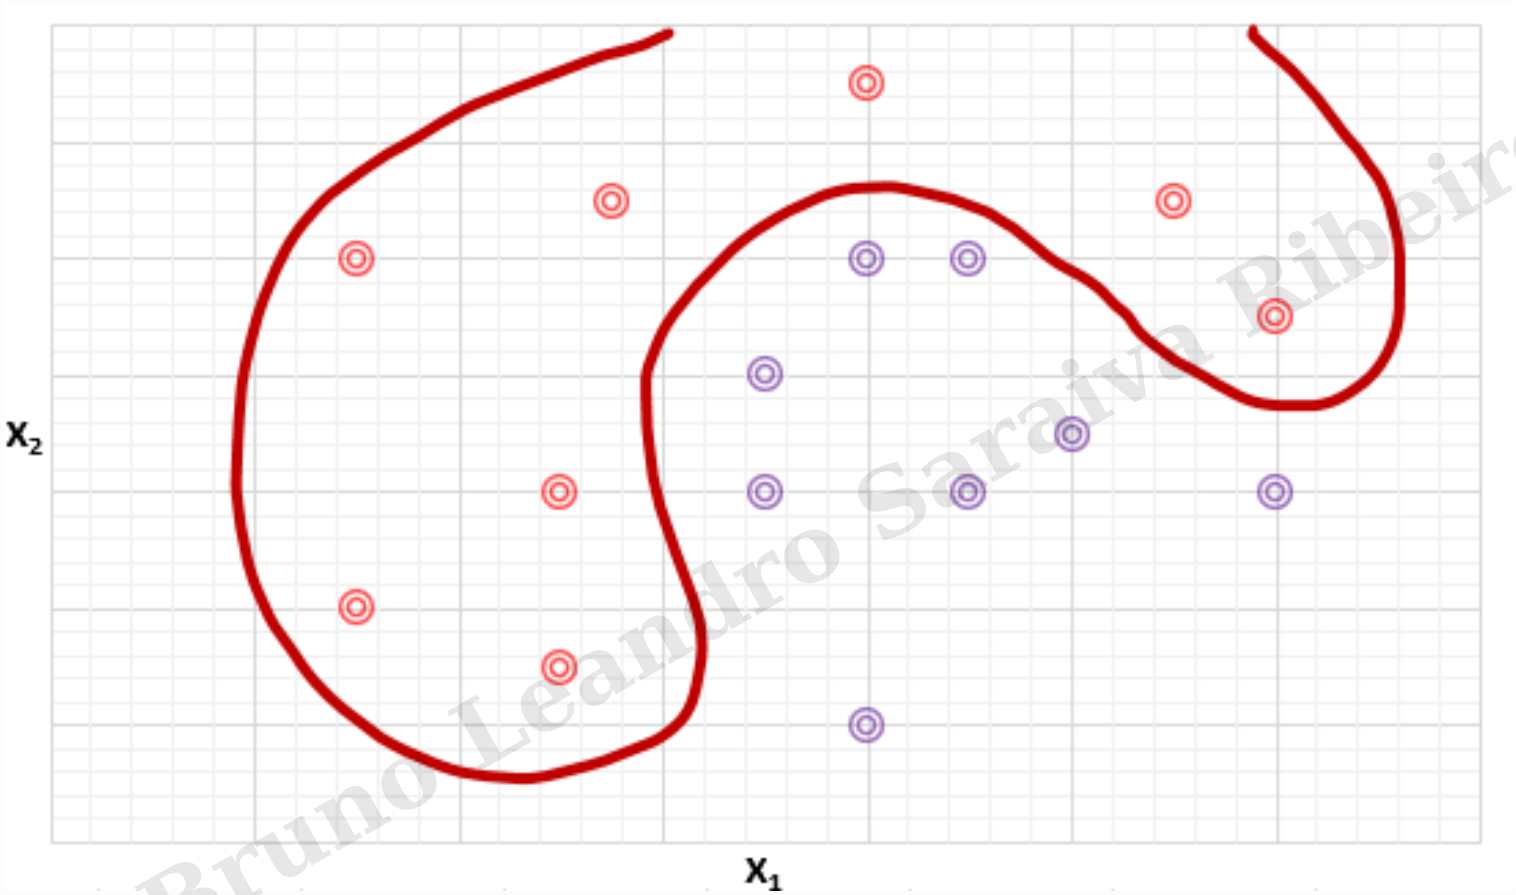
- No espaço transformado a separação é pelo hiperplano, porém ao retornar para o espaço original (X) ela se mostra não linear!

Bruno Leandro Saraiva Ribeiro 951.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear

- **Ilustração de uma solução RBF**



- **Kernel *Radial Basis Function* (RBF)**
- $K(a, b) = \exp(-\gamma \|a - b\|^2)$
  - ***a* e *b* são duas observações**
- Baseia-se na distância Euclidiana entre as observações: $\|a - b\|^2$
- Portanto, apresenta similaridade entre observações. Por meio dela, calcula-se o quanto as observações se assemelham. Varia de 0 (diferente) a 1 (semelhante)

Bruno Leandro Saraiva Ribeiro 951.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear

- **Parametrização dos kernels não lineares**

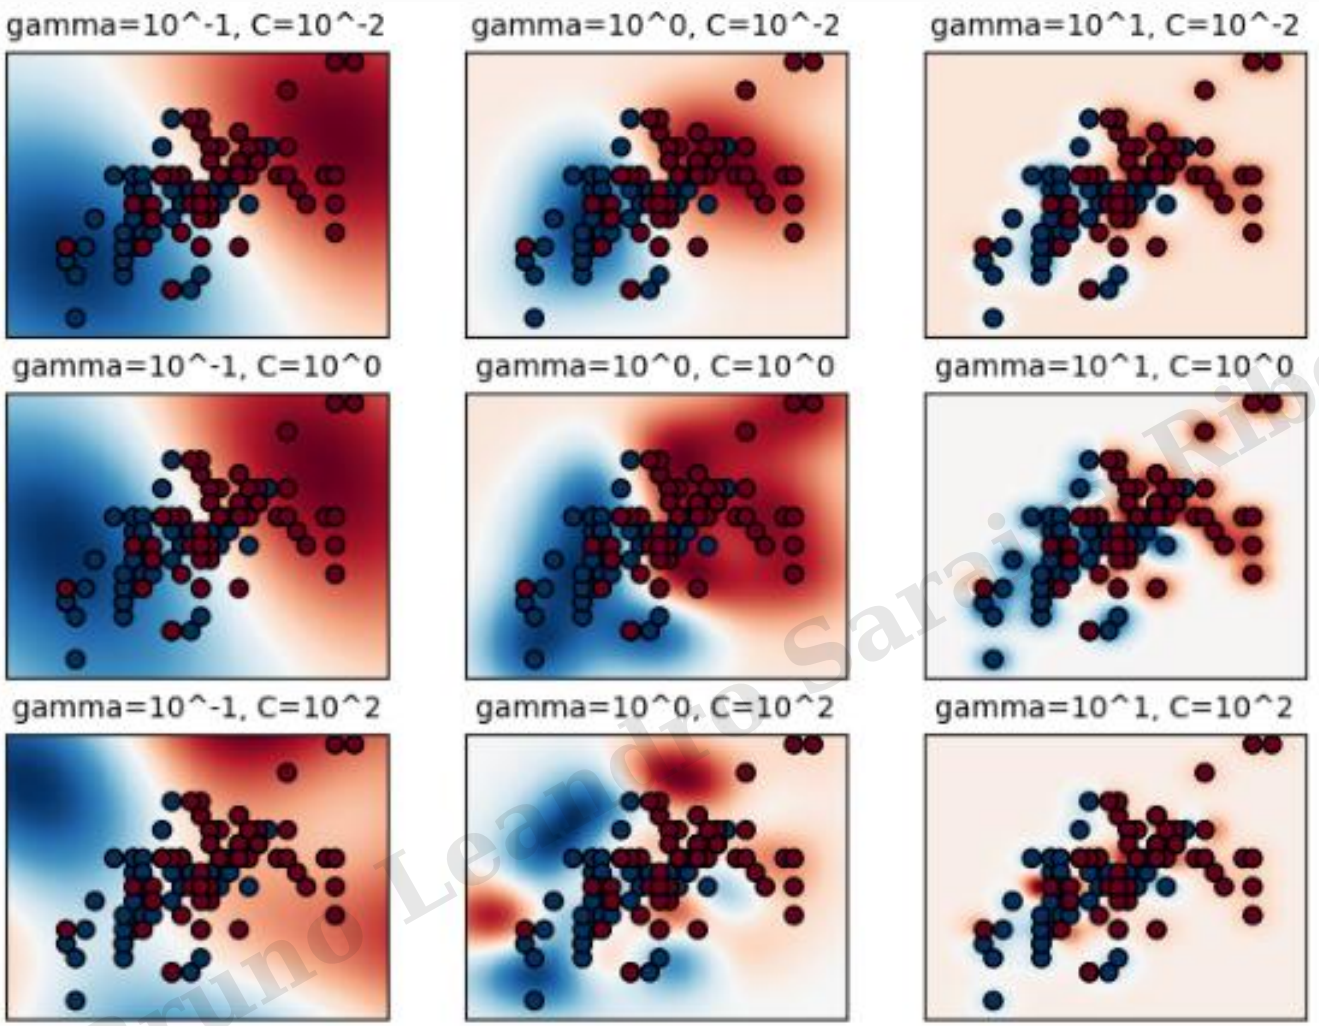
  - Hiperparâmetros no kernel polinomial:
    - **degree**: grau do polinômio (d)
    - **coef0**: contribuição relativa dos termos de maior grau vs. menor grau do polinômio (r)
    - **gamma**: intervalo de influência das observações sobre a fronteira de decisão (γ)
    - **C**: penalização atribuída às observações que violam a margem

  - Hiperparâmetros no kernel RBF:
    - **gamma**: intervalo de influência das observações sobre a fronteira de decisão (γ)
    - **C**: penalização atribuída às observações que violam a margem

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Classificação Não Linear



Fonte: https://scikit-learn.org/stable/auto_examples/svm/plot_rbf_parameters.html

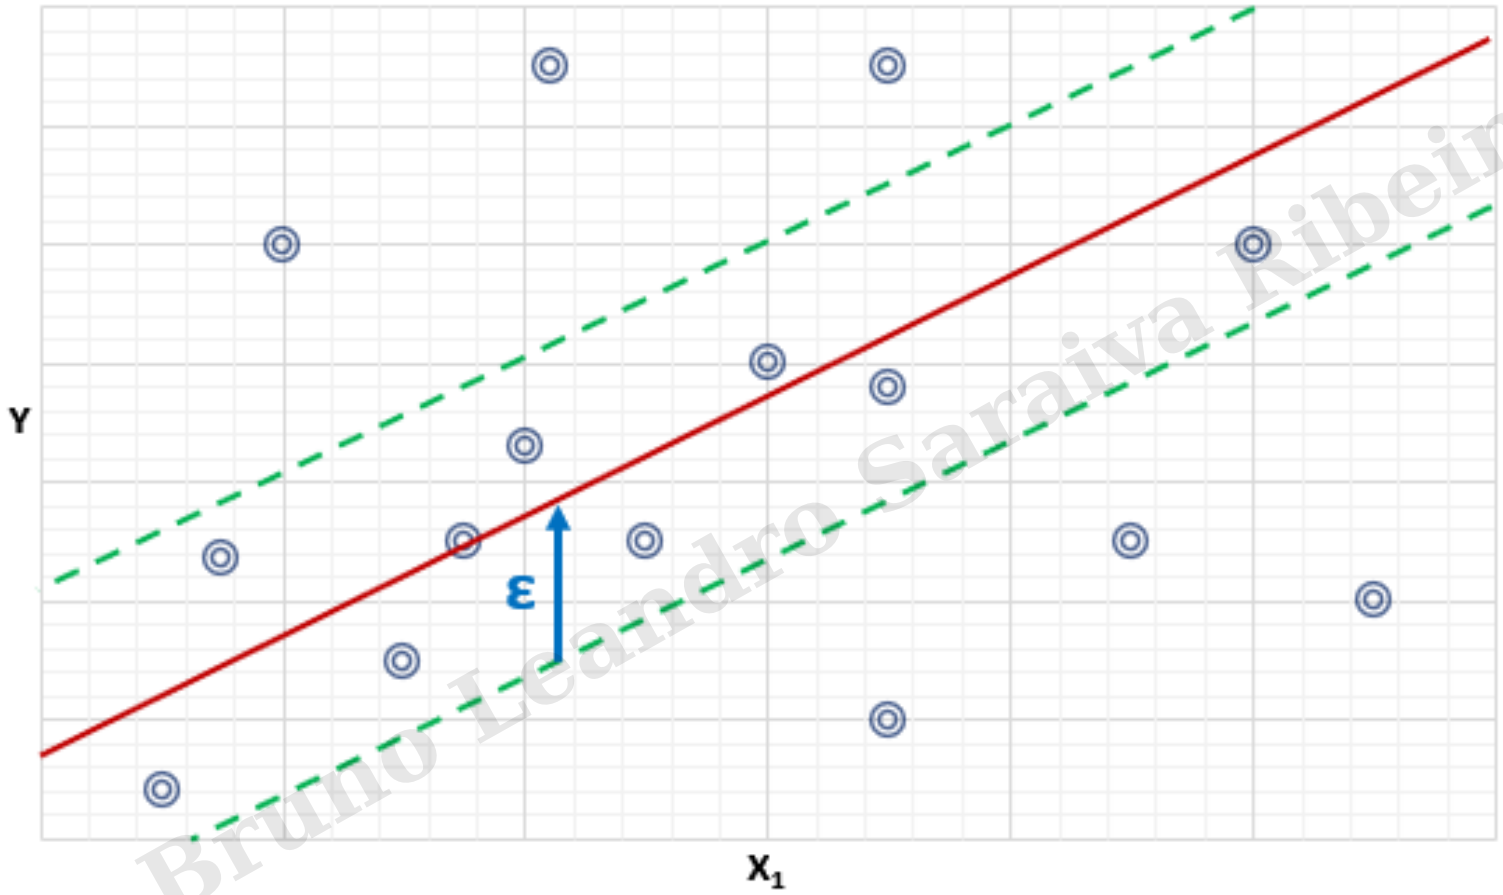
- **Exemplo de impacto dos hiperparâmetros**
- **Kernel RBF (gamma e C)**
- Para valores baixos de gamma e C, a fronteira de decisão fica mais simples e próxima da linear
- Conforme aumenta-se o C, a fronteira vai se ajustando para possibilitar menores erros de classificação e vai se tornando mais complexa
- Conforme aumenta-se o gamma, o intervalo de influência das observações fica mais justo ao redor delas (mais localizado). Isso gera fronteiras de decisões mais complexas
- **Há o impacto conjunto dos hiperparâmetros!**

Bruno Leandro Sarai Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Regressão (SVR)

- **No caso da variável dependente métrica "inverte-se o objetivo" do modelo**



- No SVR, as observações que estão dentro da margem não influenciam na solução (não são vetores de suporte). A margem pode ser interpretada como a margem de tolerância, isto é, onde os erros não são penalizados

- O hiperparâmetro específico do SVR é o **épsilon (ε)** e controla a largura da margem (tubo). Quanto maior o ε, maior é a margem

- As observações fora do tubo ou sobre a margem dele podem ser vetores de suporte

- A solução pode ser linear, polinomial e RBF (com os hiperparâmetros anteriores)

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SVM – Considerações

- **Aspectos da implementação**

  - É importante que as variáveis métricas explicativas estejam padronizadas, pois a identificação da fronteira de decisão é sensível à escala e amplitude das variáveis

  - Separação dos dados entre treino e teste: serão ajustados os hiperparâmetros do modelo

    - É viável realizar o *Grid Search* para a escolha da melhor combinação de hiperparâmetros
    - É indicado implementar a *Cross Validation* em conjunto com o *Grid Search*
    - É fundamental avaliar se ocorre o *overfitting.* Avaliação final do modelo nos dados de teste!

  - SVM de classificação pode ser aplicado às variáveis dependentes com múltiplas classes (3 ou +)

Bruno Leandro Saraiva Ribeiro 031.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Métricas de Avaliação dos Modelos

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Critérios de avaliação dos modelos: classificação

- **Como identificar a qualidade das estimativas?**

  - **Acurácia**: percentual de classificações corretas em relação ao total de observações analisadas, isto é, trata-se da eficiência geral do modelo

  - **Sensibilidade**: percentual de classificações corretas considerando apenas as observações que são evento. Essa medida também é chamada de Recall

  - **Especificidade**: percentual de classificações corretas considerando apenas as observações que não são evento

  - **Precision**: percentual de classificações corretas considerando todas as observações que o modelo classifica como evento

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Critérios de avaliação dos modelos: classificação

- **Matriz de confusão**

		Predito (Modelo)	
		Sim	Não
Observado (Real)	Sim	VP	FN
	Não	FP	VN

$$Acuracia = \frac{VP + VN}{(VP + FN + VN + FP)}$$

$$Sensibilidade = \frac{VP}{(VP + FN)}$$

$$Especificidade = \frac{VN}{(VN + FP)}$$

$$Precision = \frac{VP}{(VP + FP)}$$

$$F1\ Score = 2x\frac{Precision\ x\ Recall}{Precision + Recall}$$

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Critérios de avaliação dos modelos: regressão

- **Como identificar a qualidade das estimativas?**

- Calcula-se um **erro de previsão** fundamentado na diferença entre os valores observados e previstos para as observações. Quanto menor o erro, melhor é o ajuste do modelo estimado

- **Erro Quadrático Médio**: $MSE = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$

- **Erro Absoluto Médio**: $MAE = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$

- **Coeficiente R²**: $R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y}_i)^2}$ Obs.: quanto mais próximo de 1 estiver o R², melhor!

Bruno Leandro Saraiva Ribeiro 031.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Escolha dos Hiperparâmetros

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Grid Search e Validação Cruzada

- **Implementação**

  - Os hiperparâmetros podem ser selecionados por meio de diversos experimentos para encontrar uma combinação para seus valores que aperfeiçoe o desempenho do modelo

  - A seguir, o passo a passo ilustra a realização de um Grid Search com Validação Cruzada:

    - Escolher os hiperparâmetros que serão ajustados e quais valores serão avaliados
    - Criar uma lista com todas essas combinações de valores dos hiperparâmetros definidos
    - Treinar, com validação cruzada, os modelos para cada uma das combinações de hiperparâmetros
    - Definir uma métrica de avaliação e comparação para os modelos (exemplos: acurácia ou MSE)
    - Atribuir a melhor combinação de hiperparâmetros ao modelo com a melhor avaliação

Bruno Leandro Sanaiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Grid Search e Validação Cruzada

- **Validação Cruzada (*Cross-Validation*)**

  - Técnica aplicada com o intuito de avaliar os modelos e selecionar os hiperparâmetros que gerem a maior capacidade de generalização dos resultados

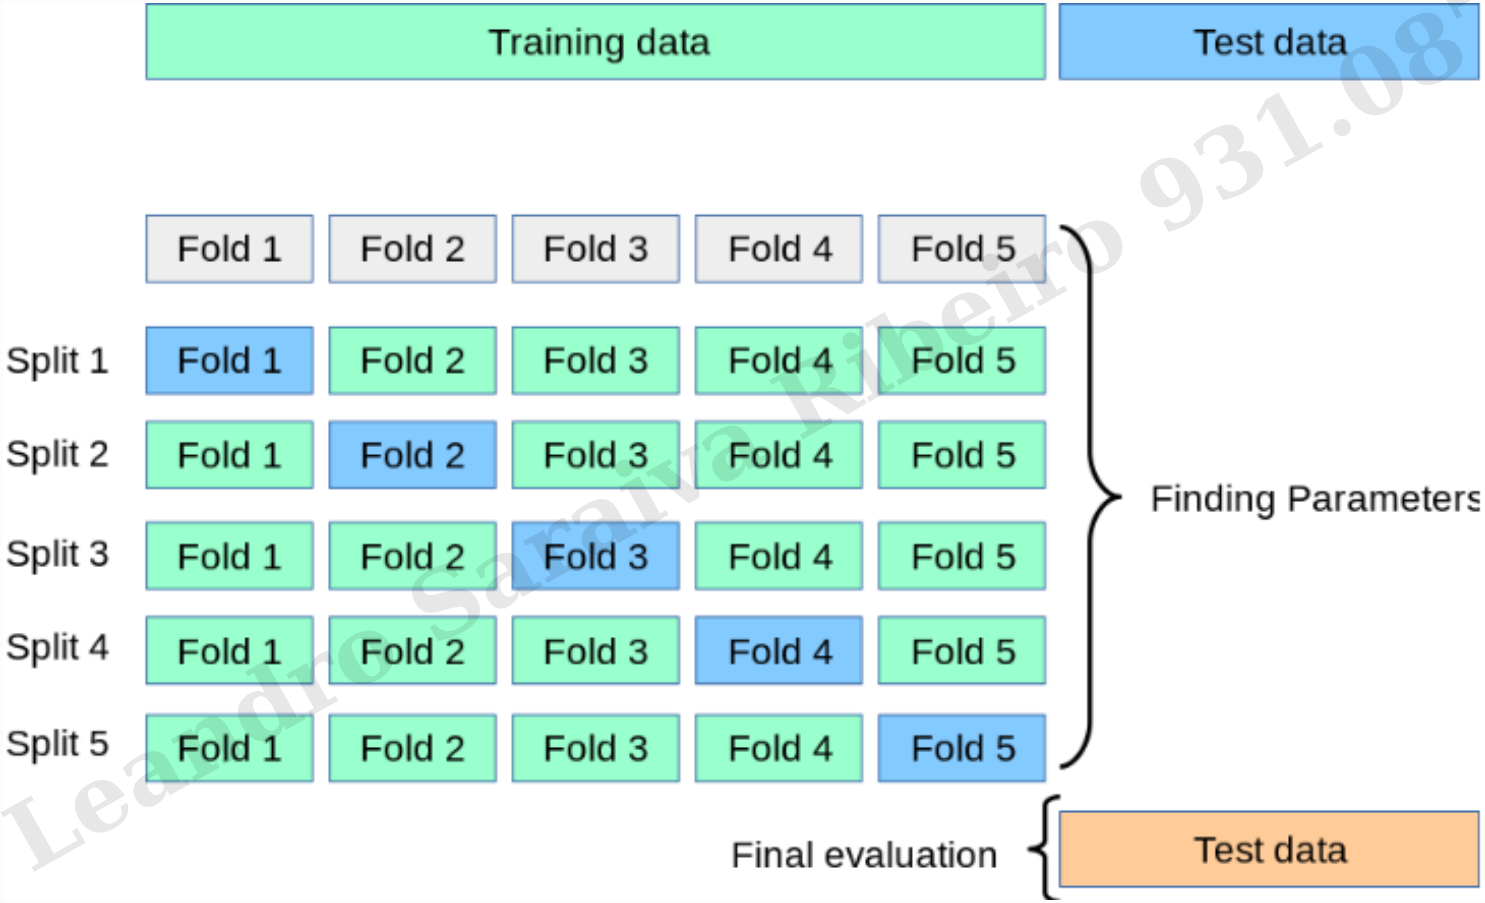
  - Validação cruzada *k-fold*: a **amostra de treinamento** é dividida em *k* partes menores (*folds*)

    - Na prática, é comum usar a divisão em 5 partes (*folds*)
    - A cada rodada, *k* – 1 partes são utilizadas para o treinamento do modelo e a outra parte remanescente fica para avaliação do desempenho
    - O procedimento ocorre *k* vezes, pois cada *fold* será usada uma vez para a avaliação
    - O desempenho relacionado a cada combinação de hiperparâmetros é agregado pela média dos desempenhos nas *folds* de avaliação
    - A validação cruzada é aplicada mesmo existindo a divisão inicial entre dados de treino e teste

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Validação Cruzada



Fonte: https://scikit-learn.org/stable/modules/cross_validation.html#cross-validation

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sugestões de Leituras/Referências

- Géron, A. (2021). Mãos à obra aprendizado de máquina com Scikit-Learn, Keras & TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Alta Books.

- SVM Classificação: https://scikit-learn.org/stable/modules/svm.html#svm-classification

- SVM Regressão: https://scikit-learn.org/stable/modules/svm.html#svm-regression

- Problema de otimização do SVM: https://scikit-learn.org/stable/modules/svm.html#svm-mathematical-formulation

Bruno Leandro Saraiva Ribeiro 931.087.883-53

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Wilson Tarantin Jr. | linkedin.com/in/wilson-tarantin-junior-359476190

Bruno Leandro Saraiva Ribeiro 931.087.883-53